

[제1과목: 데이터 이해]

1. 데이터 웨어하우스(Data Warehouse)의 고유한 4가지 특성에 포함되지 않는 것은 무엇인가?

- ① 주제 지향성 (Subject-oriented)
- ② 통합성 (Integrated)
- ③ 휘발성 (Volatile)
- ④ 시계열성 (Time-variant)

2. 지식경영의 SECI 모델에서 "조직 내에 축적된 매뉴얼, 지침서 등의 형식지(Explicit Knowledge)들을 서로 결합하고 가공하여, 새로운 데이터베이스나 전사적 지식 시스템이라는 더 고도화된 형식지로 창출해 내는 과정"은?

- ① 공통화 (Socialization)
- ② 표출화 (Externalization)
- ③ 연결화 (Combination)
- ④ 내면화 (Internalization)

3. 빅데이터의 3대 핵심 특징(3V) 중 하나인 '다양성(Variety)'에 대한 설명으로 가장 적절한 것은?

- ① 데이터의 생성 및 처리 속도가 실시간에 가깝게 폭발적으로 증가하는 현상
- ② 텍스트, 오디오, 비디오, 로그 파일 등 비정형 데이터와 반정형 데이터가 급증하는 현상
- ③ 데이터의 저장 용량이 테라바이트(TB)를 넘어 페타바이트(PB) 이상으로 거대해지는 현상
- ④ 데이터에 담긴 가치(Value)가 비즈니스에 직접적인 이익을 가져다주는 현상

4. 개인정보 비식별화 처리 기법 중 "주민등록번호나 이름 등 고유 식별 정보를 다른 가짜 문자열이나 일련번호로 1:1 매핑하여 대체하는 기법"은?

- ① 총계처리 (Aggregation)
- ② 범주화 (Data Suppression)
- ③ 가명처리 (Pseudonymization)
- ④ 데이터 마스킹 (Data Masking)

5. 다음 중 데이터와 정보의 관계를 설명하는 DIKW 피라미드 모델의 각 단계와 예시가 가장 알맞게 짝지어진 것은?

- ① 데이터(Data): A 주식은 어제 5만원, B 주식은 6만원에 거래되었다.
 - ② 정보(Information): B 주식의 가격이 A 주식보다 장기적으로 우상향할 것이므로 B 주식을 사야겠다.
 - ③ 지식(Knowledge): A 주식과 B 주식의 가격 차이는 1만원이다.
 - ④ 지혜(Wisdom): 주식 투자를 할 때 분산 투자를 하는 것이 리스크를 줄일 수 있는 근본 원리이다.
-

6. 빅데이터 시대의 위기 요인 중 하나인 '데이터 오용(Data Misuse)'을 방지하기 위해 대두된 패러다임(통제 방안)은 무엇인가?

- ① 알고리즘의 소스코드를 대중에게 무조건 전면 공개한다.
 - ② 분석 결과가 미칠 영향을 고려하여 '결과 기반 책임제'로 전환한다.
 - ③ 무조건적인 데이터 수집 사전 동의제를 더욱 강화한다.
 - ④ 피해를 입은 사람을 구제하기 위해 '알고리즘 접근권'을 허용한다.
-

7. 데이터베이스의 일반적인 4가지 특징 중 "저장된 데이터는 고정되어 있지 않고, 새로운 데이터의 삽입(Insert), 수정(Update), 삭제>Delete)를 통해 항상 최신의 상태로 변화한다"는 특징은?

- ① 공용 데이터 (Shared Data)
 - ② 통합 데이터 (Integrated Data)
 - ③ 운영 데이터 (Operational Data)
 - ④ 저장 데이터 (Stored Data)
-

8. 다음 중 데이터 사이언티스트에게 요구되는 역량 중 '하드 스킬(Hard Skill)'에 해당하는 것만 묶인 것은?

- ① 커뮤니케이션 능력, 통찰력
 - ② 머신러닝 모형 아키텍처 설계, 분산 컴퓨팅 환경 데이터 수집 기술
 - ③ 데이터 시각화 결과 기반 스토리텔링, 최적의 비즈니스 문제 정의
 - ④ 프레젠테이션 스킬, 리더십
-

9. 데이터 크기 단위의 변환 중 수학적으로 옳바르지 않은 것은?

- ① 1 PB (Petabyte) = 1024 TB
 - ② 1 EB (Exabyte) = 1024 PB
 - ③ 1 ZB (Zettabyte) = 1024 YB
 - ④ 1 YB (Yottabyte) = 1024 ZB
-

10. 빅데이터가 경제 및 사회 발전에 미치는 긍정적 역할에 대한 비유 중 "다양한 사업자들에게 동력을 제공하고 새로운 비즈니스를 창출할 수 있게 해준다"는 의미를 담은 비유적 표현은?

- ① 차세대 산업혁명의 석탄/철광석
- ② 21세기의 원유(Oil)
- ③ 렌즈(Lens)
- ④ 플랫폼(Platform)

[제2과목: 데이터 분석 기획]

11. 데이터 분석 주제 발굴의 4가지 유형 중 "해결해야 할 분석 대상(What)은 잘 모르지만, 구체적인 분석 방법론이나 데이터 처리 기법(How)은 명확하게 알고 있을 때" 새로운 지식이나 가치를 찾아내는 유형은?

- ① 최적화 (Optimization)
- ② 솔루션 (Solution)
- ③ 통찰 (Insight)
- ④ 발견 (Discovery)

12. 하향식 접근법(Top-down Approach)의 '문제 탐색(Problem Discovery)' 단계에서 비즈니스 모델(Business Model)을 기반으로 과제를 발굴하고자 한다. 이 캔버스의 5가지 주요 탐색 영역에 포함되지 않는 것은?

- ① 업무 (Operation)
- ② 제품 (Product)
- ③ 고객 (Customer)
- ④ 솔루션 인프라 (Solution Infrastructure)

13. 상향식 접근법(Bottom-up Approach)을 사용하는 것이 가장 적절한 비즈니스 상황은?

- ① 경영진이 '올해 3분기 매출 하락 원인을 회귀분석으로 찾아내라'고 구체적으로 지시한 경우
- ② 해결해야 할 문제가 무엇인지 아직 불명확하여, 보유한 대규모 데이터를 탐색적으로 파헤쳐(EDA) 새로운 패턴을 도출하고자 할 경우
- ③ 콜센터 불만율을 낮추기 위해 기존의 실패 사례들을 단계별로 점검할 경우
- ④ 고객 세분화를 위해 기존에 성공했던 벤치마킹 방법론을 그대로 도입할 경우

14. CRISP-DM(Cross Industry Standard Process for Data Mining) 분석 방법론에서 "도출된 분석 모델을 실제 현업 비즈니스 환경에 적용하고, 유지보수 계획을 수립하는 가장 마지막 단계"는 무엇인가?

- ① 업무 이해 (Business Understanding)

- ② 평가 (Evaluation)
 - ③ 전개 (Deployment)
 - ④ 데이터 준비 (Data Preparation)
-

15. 데이터 분석 마스터 플랜 수립 시 우선순위를 설정하기 위한 평가 축(Criteria)에 대한 설명으로 옳바른 것은?

- ① '시급성'은 주로 데이터의 양, 정형/비정형 여부 등 데이터 확보 수준에 따라 결정된다.
 - ② '난이도'는 이 분석 과제가 비즈니스 목표(ROI)에 얼마나 큰 이익을 가져다주는지에 따라 결정된다.
 - ③ 포트폴리오 사분면 분석에서 1순위로 추진해야 할 과제는 '시급성이 높고 난이도는 쉬운' 과제이다.
 - ④ 투자비용(Investment) 요소는 분석 결과를 통해 창출되는 전략적 가치를 의미한다.
-

16. 조직의 데이터 분석 수준 진단 사분면 모델에서 "데이터 분석 조직, 인력, IT 인프라 등 분석의 기본 요건(준비도, Readiness)은 전혀 갖추어지지 않았지만, 일부 현업 부서에서 주먹구구식으로 분석을 도입해 내부 프로세스(성숙도, Maturity) 점수만 일부 높게 측정된 기업"의 유형은?

- ① 도입형
 - ② 정착형
 - ③ 확산형
 - ④ 준비형
-

17. 기업 내 데이터 거버넌스(Data Governance) 체계를 구축할 때 필수적으로 확립해야 하는 3대 핵심 프레임워크(구성요소)로만 바르게 묶인 것은?

- ① 원칙(Principle), 조직(Organization), 프로세스(Process)
 - ② 인력(People), 비용(Budget), 기술(Technology)
 - ③ 데이터 표준화(Standard), 데이터 품질(Quality), 메타데이터(Metadata)
 - ④ 저장소(Storage), 보안(Security), 활용(Usage)
-

18. 데이터 분석을 효과적으로 추진하기 위한 분석 조직 구조 모델 중 "별도의 독립된 전담 분석 조직을 구성하지 않고, 재무/마케팅/인사 등 각 현업 부서 내에 분석 인력을 배치하여 부서별로 독자적인 과제를 수행하는 조직 형태"는?

- ① 집중형 조직 (Centralized)
 - ② 분산형 조직 (Decentralized)
 - ③ 기능 중심형 조직 (Functional)
 - ④ 매트릭스 조직 (Matrix)
-

19. 분석 기획 시 작성하는 '분석 과제 정의서(Project Definition)'에 포함되어야 할 항목으로 가장 거리가 먼 것은?

- ① 해결하고자 하는 비즈니스 질문과 분석 목적
- ② 과제 수행에 필요한 소스 데이터(Source Data)의 위치 및 내용
- ③ 과제 완료 후 적용 시 예상되는 비즈니스 정량/정성적 기대 효과
- ④ 최종 배포될 머신러닝 앙상블 모델의 구체적인 하이퍼파라미터 수치

20. 분석 마스터플랜 기획 단계에서 고려해야 할 '5대 주요 속성(5 Key Attributes)'에 해당하지 않는 것은?

- ① 데이터 크기 (Data Size)
- ② 분석의 속도 (Speed)
- ③ 모델의 정확도와 정밀도 (Accuracy & Precision)
- ④ 분석가 연봉 예산 (Analyst Salary Budget)

[제3과목: 데이터 분석]

21. 데이터 측정 척도 중 "순서와 서열 정보뿐만 아니라 각 값들 사이의 간격(Difference)이 수치적으로 의미가 있어 덧셈과 뺄셈이 가능하지만, 절대적인 영점(0)이 없어 나눗셈 등 비율 계산은 불가능한 척도(예: 섭씨온도)"는?

- ① 명목척도
- ② 서열척도
- ③ 등간척도
- ④ 비율척도

22. 이상치(Outlier)를 판별하는 방법 중, 데이터가 정규분포를 따른다고 가정할 때 평균으로부터 표준편차(σ)의 몇 배 이상 떨어진 값을 극단적 이상치로 판단하는가? (가장 보편적인 경험 법칙 척도 기준)

- ① 1.5σ
- ② 2.0σ
- ③ 3.0σ
- ④ 5.0σ

23. 아래 표는 어떤 연속형 데이터셋을 상자그림(Boxplot)으로 시각화하기 위해 산출한 통계량이다. 이상치(Outlier)로 판정되지 않는 정상 범위(Normal Range) 구간으로 올바른 것은?

통계 지표	값
제3사분위수 (Q3)	45
제1사분위수 (Q1)	25

- ① 25 ~ 45
- ② 5 ~ 65
- ③ -5 ~ 75
- ④ 0 ~ 70

24. 통계적 가설검정에서 "실제로 귀무가설(H_0)이 거짓(즉, 대립가설이 참)임에도 불구하고, 표본 오차로 인해 귀무가설을 기각하지 못하고 잘못 채택하게 되는 통계적 오류"의 명칭은?

- ① 제1종 오류
- ② 제2종 오류
- ③ 유의수준 한계 오류
- ④ 검정력 부족 오류

25. 추출된 표본통계량 분포를 설명하는 수학적 원리 중 "모집단의 고유 분포 형태가 어떠한 상관없이, 표본의 크기(n)가 충분히 크면 그 표본 평균들의 분포는 결국 정규분포에 근사하게 된다"는 정리는 무엇인가?

- ① 대수의 법칙 (Law of Large Numbers)
- ② 중심극한정리 (Central Limit Theorem)
- ③ 베이즈 정리 (Bayes' Theorem)
- ④ 가우스-마르코프 정리

26. 표본추출(Sampling) 방법 중 "모집단을 이질적인 구성원을 가진 여러 개의 군집(예: 각 학교의 학급들)으로 나눈 뒤, 그중 일부 군집만을 무작위로 추출하여 해당 군집 내의 모든 개체를 전수조사하는 방식"은?

- ① 층화추출법 (Stratified Sampling)
- ② 집락추출법 (Cluster Sampling)
- ③ 계통추출법 (Systematic Sampling)
- ④ 단순무작위추출법 (Simple Random Sampling)

27. 피어슨(Pearson) 선형 상관계수 r 에 대한 설명으로 옳바르지 않은 것은?

- ① $r = 1$ 또는 $r = -1$ 에 가까울수록 두 변수 간의 직선(선형) 관계가 강하다.

- ② $r = 0$ 이 도출되면 두 변수 간에는 어떠한 2차, 3차 곡선 형태의 비선형 관계도 존재하지 않는다.
- ③ 두 변수의 공분산을 각각의 표준편차의 곱으로 나누어 산출한다.
- ④ 상관계수 값이 크다고 하여 두 변수 간에 뚜렷한 '인과관계'가 있다고 단정 지을 수는 없다.

28. 선형회귀분석의 오차항(잔차)이 충족해야 하는 4가지 기본 가정 중 "독립변수의 모든 값 구역에서 잔차의 퍼짐 정도(분산)가 일정하게 상수를 유지해야 한다"는 가정은 무엇인가?

- ① 선형성 (Linearity)
- ② 독립성 (Independence)
- ③ 등분산성 (Homoscedasticity)
- ④ 정규성 (Normality)

29. 다중회귀분석 과정에서 회귀 모형의 유의성을 검정하기 위해 도출한 분산분석표(ANOVA)의 정보가 아래와 같다. 이 모형의 검정통계량인 F-값(F-statistic)은 얼마인가?

요인	자유도 (df)	제곱합 (SS)
회귀 (Regression)	2	600
잔차 (Error)	20	200
총계 (Total)	22	800

- ① 3
- ② 10
- ③ 30
- ④ 60

30. 다중회귀분석에서 독립변수들끼리 지나치게 높은 상관관계를 맺고 있어, 회귀계수의 분산이 팽창하고 추정의 신뢰도가 떨어지는 현상을 진단하기 위해 계산하는 지표(보통 10 이상일 때 심각하다고 판단)는 무엇인가?

- ① 더빈-왓슨 통계량 (Durbin-Watson)
- ② 분산팽창요인 (VIF)
- ③ 쿡의 거리 (Cook's Distance)
- ④ 수정된 결정계수 (Adjusted R2)

31. 회귀분석의 변수 선택법(Feature Selection) 중 "절편만 있는 빈 깡통 모형에서 출발하여, 타깃 예측에 가장 기여도가 높고 유의한 변수를 하나씩 순차적으로 추가해 나가는 알고리즘"은?

- ① 후진 제거법

- ② 전진 선택법
 - ③ 단계별 선택법
 - ④ 벌점 규제법 (Lasso/Ridge)
-

32. 종속변수가 범주형(성공/실패 등)일 때 사용하는 로지스틱 회귀분석(Logistic Regression)에서 '오즈(Odds)'의 값이 3으로 계산되었다고 가정하자. 이 사건이 발생할 확률(P)은 얼마인가? (참고: $Odds = P / (1-P)$)

- ① 0.33
 - ② 0.50
 - ③ 0.75
 - ④ 0.80
-

33. 비정상 시계열 데이터를 분석 가능한 정상 시계열로 변환하려 한다. 시계열 데이터의 "시간이 흐름에 따라 분산(변동폭)이 일정하지 않고 계속 커지는 이분산성"을 상쇄하기 위해 적용하는 가장 적절한 조치는 무엇인가?

- ① 차분 (Differencing)
 - ② 더미 변수화
 - ③ 이동평균 스무딩
 - ④ 로그 변환 (Log Transformation)
-

34. 시계열 분석의 ARIMA(p, d, q) 모형에 대한 설명 중 각 파라미터가 의미하는 바가 올바르지 않은 것은?

- ① p: 현재 값이 과거 자신의 값들에 얼마나 의존하는지를 나타내는 자기회귀(AR) 차수
 - ② q: 백색잡음(오차)의 과거 결합 흐름에 의존하는 이동평균(MA) 차수
 - ③ d: 비정상 시계열을 정상 시계열로 만들기 위해 필요한 차분(Differencing) 횟수
 - ④ d: 모형의 독립변수 간의 상관성을 뜻하는 다중공선성 차수
-

35. 분류 분석을 위한 의사결정나무 모델에서 각 마디(Node)를 분할할 때 사용하는 불순도 지표 중 "정보 이론(Information Theory)의 불확실성을 바탕으로 하며, 마디 내 범주 비율이 50:50으로 완전히 섞여 있을 때 최댓값 1을 가지는 지표"는 무엇인가?

- ① 지니 지수 (Gini Index)
 - ② 엔트로피 지수 (Entropy Index)
 - ③ 카이제곱 통계량
 - ④ 오차제곱합 (SSE)
-

36. 의사결정나무 형성 과정에서 어떤 특정 마디(Node) 내부의 데이터 클래스 분포를 조사한 결과가 아래 표와 같다. 이 마디의 지니 지수(Gini Index) 값을 계산하시오.

클래스 범주	데이터 개수
양성 (Positive)	30개
음성 (Negative)	70개
합계	100개

- ① 0.21
- ② 0.42
- ③ 0.49
- ④ 0.58

37. 인공지능망의 은닉층에 사용되는 활성화 함수(Activation Function) 중 "출력 범위를 -1에서 1 사이로 변환해 주어, 시그모이드(Sigmoid) 함수의 중심 편향 문제를 보정하고 기울기 소실을 일부 완화한 함수"는 무엇인가?

- ① 시그모이드 함수
- ② 하이퍼볼릭 탄젠트 함수 (Tanh)
- ③ 렐루 함수 (ReLU)
- ④ 소프트맥스 함수

38. 인공지능망 가중치 최적화 과정에서 출력층의 오차를 앞쪽(입력층 방향)으로 돌려보내며 연쇄 법칙 편미분을 통해 은닉층 가중치를 업데이트하는 딥러닝의 핵심 학습 알고리즘은?

- ① 로짓 변환 알고리즘
- ② 역전파 알고리즘 (Backpropagation)
- ③ 경사 상승법
- ④ 엘보우 기법

39. 앙상블 학습 기법 중 배깅(Bagging)을 기반으로 하되, "개별 의사결정나무를 만들 때 분할 기준 변수를 전체 변수 중에서 찾지 않고, 무작위로 일부 변수 부분집합(Random Feature Subset)만 추출하여 모델 간의 상관관계를 낮춰 숲의 분산을 대폭 감소시킨 모델"은?

- ① 에이다부스트 (AdaBoost)
- ② 그래디언트 부스팅 머신 (GBM)
- ③ 스택킹 (Stacking)
- ④ 랜덤 포레스트 (Random Forest)

40. 다음 표는 어떤 분류 모델의 혼동행렬(Confusion Matrix)이다. 이 모델의 거짓 긍정률(False Positive Rate, FPR = 1 - 특이도) 값은 얼마인가?

실제 / 예측	참(True)으로 예측	거짓(False)으로 예측
실제 참(True)	70 (TP)	30 (FN)
실제 거짓(False)	20 (FP)	80 (TN)

- ① 0.20
- ② 0.25
- ③ 0.70
- ④ 0.80

41. 모델 평가를 위한 ROC(Receiver Operating Characteristic) 곡선에 대한 설명으로 가장 올바른 것은?

- ① X축은 정밀도(Precision), Y축은 재현율(Recall)이다.
- ② ROC 곡선이 대각선($y=x$)에 완벽히 일치할 때, 모델의 분류 성능이 가장 100% 우수함을 뜻한다.
- ③ 곡선 아래 면적을 뜻하는 AUC(Area Under Curve) 값이 1에 가까울수록 모델 성능이 뛰어나다.
- ④ 분류 임계값(Threshold) 변화에 상관없이 항상 고정된 단일 점 좌표를 출력한다.

42. 다음 중 사전에 목표 변수(Target Label, Y)가 정해져 있지 않은 상태에서 데이터 항목 간의 기하학적 유사도나 구조만을 이용해 패턴을 찾는 비지도 학습(Unsupervised Learning) 기법이 아닌 것은?

- ① K-means 군집분석
- ② 다차원척도법 (MDS)
- ③ 연관규칙분석 (Association Rules)
- ④ 로지스틱 회귀분석

43. K-means 군집분석에 대한 설명으로 가장 옳지 않은 것은?

- ① 초기에 분석가가 설정해야 하는 하이퍼파라미터 k값에 따라 최종 결과가 크게 달라질 수 있다.
- ② 초기 중심점(Centroid)의 무작위 배정 위치에 따라 로컬 미니마에 빠져 수렴 결과가 매번 변동될 위험이 있다.
- ③ 거리 연산이 불가능한 순수 범주형(명목형) 데이터 텍스트만 주어져도 아무런 전처리 변환 없이 즉각 완벽히 분류해 낸다.

- ④ 밀집된 구형(원형) 군집을 찾는 데는 매우 우수하지만, 초승달처럼 기하학적으로 길쭉하게 휘어진 밀도 군집을 구별하는 데는 취약하다.

44. 계층적 군집분석 수행 시 두 군집 간 거리를 측정하는 여러 연결법(Linkage Method) 중 "두 군집 내의 모든 개체 간의 거리를 각각 계산한 후, 그 거리들의 산술 평균을 구하여 두 군집 간의 대표 거리로 정의하는 방식"은?

- ① 단일 연결법 (Single Linkage)
② 완전 연결법 (Complete Linkage)
③ 평균 연결법 (Average Linkage)
④ 와드 연결법 (Ward's Method)

45. 차원 축소를 위해 주성분 분석(PCA)을 시행하여 아래와 같은 누적 기여율(Cumulative Proportion) 표를 얻었다. 원본 데이터가 가진 정보(분산)를 최소 80% 이상 보존하여 설명하고자 할 때, 선택해야 하는 가장 적은 주성분의 개수는 몇 개인가?

주성분 (PC)	개별 분산 설명률	누적 분산 설명률
PC 1	45%	45%
PC 2	25%	70%
PC 3	12%	82%
PC 4	10%	92%
PC 5	8%	100%

- ① 1개
② 2개
③ 3개
④ 4개

46. 고객의 구매 이력 등 고차원 변수 공간에 존재하는 개체들 간의 유사성(유클리드 거리 등)을 측정하여, 데이터를 시각적으로 직관 파악할 수 있도록 2차원 또는 3차원의 저차원 평면 좌표에 점으로 사상시키는 시각화 분석 기법은 무엇인가?

- ① 다차원척도법 (MDS)
② 서포트 벡터 머신 (SVM)
③ 의사결정나무
④ Apriori 알고리즘

47. 장바구니 연관규칙분석에서 품목 X와 Y의 거래 빈도를 조사한 결과가 다음과 같다. 규칙 X->Y의 신뢰도(C Confidence) 값은 얼마인가?

지표 항목	거래 건수
전체 총 거래 건수	1000건
품목 X 구매 건수	200건
품목 Y 구매 건수	300건
품목 X와 Y 동시 구매 건수	50건

- ① 0.16 (50/300)
- ② 0.25 (50/200)
- ③ 0.50 (100/200)
- ④ 1.20 (Lift 값)

48. 다음 연관규칙분석 알고리즘 중 가장 고전적이면서도 널리 쓰이는 기법으로, "최소 지지도(Minimum Support)의 임계치를 정해놓고 그 기준을 넘지 못하는 품목 조합은 상위 조합 연산에서 아예 가지치기(Pruning)하여 배제시킴으로써 컴퓨터의 계산 부담을 폭발적으로 줄인 알고리즘"은?

- ① DBSCAN
- ② SOM
- ③ Apriori 알고리즘
- ④ K-medoids

49. 데이터 모델링 시 원본 데이터셋을 훈련용(Train), 검증용(Validation), 평가용(Test)으로 분할하여 사용한다. 이 중 '평가용(Test) 데이터'의 가장 주된 역할은 무엇인가?

- ① 모델 내 알고리즘의 순수 가중치와 편향 파라미터를 학습시키는 용도
- ② 학습 과정 중 여러 모델의 하이퍼파라미터를 튜닝하고 최적 모델을 선정하기 위한 중간 모니터링 용도
- ③ 훈련에 전혀 노출되지 않은 데이터를 사용하여 최종 확정된 모델의 미래 실제 일반화 예측 성능을 객관적으로 평가하는 용도
- ④ 데이터의 분포나 이상치를 파악하기 위해 EDA를 수행하는 최초 소스 데이터

50. 확률 추출 방법 중 하나로, "모집단을 서로 겹치지 않는 동질적인 여러 개의 층(Strata, 예: 학년별, 직급별)으로 나눈 뒤, 모든 층에서 각각 무작위로 일정 비율의 표본을 골고루 추출해 내어 모집단의 대표성을 훌륭하게 보장하는 기법"은?

- ① 단순무작위추출법
 - ② 층화추출법 (Stratified Sampling)
 - ③ 집락추출법 (Cluster Sampling)
 - ④ 계통추출법
-

제3회 ADsP AI 모의고사

번호	정답	번호	정답	번호	정답	번호	정답	번호	정답
1	③	11	③	21	③	31	③	41	③
2	③	12	④	22	②	32	③	42	④
3	②	13	②	23	③	33	④	43	③
4	③	14	③	24	②	34	④	44	③
5	①	15	③	25	②	35	②	45	③
6	②	16	②	26	②	36	②	46	①
7	③	17	①	27	②	37	②	47	②
8	②	18	③	28	③	38	②	48	③
9	③	19	④	29	③	39	④	49	③
10	④	20	④	30	②	40	①	50	②

제3회 ADsP AI 모의고사

[제1과목: 데이터 이해]

1번 정답: ③ 휘발성 (Volatile)

데이터 웨어하우스(DW)는 보관된 데이터가 수시로 지워지거나 갱신되지 않고 영구히 보존되는 비휘발성(Non-volatile)을 지닙니다.

2번 정답: ③ 연결화 (Combination)

기존의 매뉴얼, 지침서(형식지)들을 취합해 고도화된 통합 시스템(형식지)으로 가공 결합하는 단계는 연결화입니다.

3번 정답: ② 텍스트, 오디오, 비디오, 로그 파일 등 비정형 데이터와 반정형 데이터가 급증하는 현상

빅데이터 3V 중 다양성(Variety)은 데이터의 형태가 정형을 넘어 텍스트, 멀티미디어 등 비정형/반정형 데이터가 급증하는 것을 뜻합니다.

4번 정답: ③ 가명처리 (Pseudonymization)

개인을 식별할 수 있는 고유 키 값을 가짜 문자열로 1:1 대체 매핑하는 기법은 가명처리입니다.

5번 정답: ① 데이터(Data): A 주식은 어제 5만원, B 주식은 6만원에 거래되었다.

데이터(Data)는 가공되지 않은 순수 사실을 뜻합니다. ②번은 지혜, ③번은 정보, ④번은 지식의 속성이 섞여 있습니다.

6번 정답: ② 분석 결과가 미칠 영향을 고려하여 '결과 기반 책임제'로 전환한다.

모델의 부당한 판정으로 발생하는 오용 및 책임 소재 불분명 문제를 막기 위해 사전 수집 통제보다는 사후 결과 기반 책임제로 패러다임이 이동합니다.

7번 정답: ③ 운영 데이터 (Operational Data)

데이터가 삽입, 갱신, 삭제를 통해 항상 살아 숨 쉬며 최신 상태를 유지해야 하는 시스템 고유 특성은 운영 데이터입니다.

8번 정답: ② 머신러닝 모형 아키텍처 설계, 분산 컴퓨팅 환경 데이터 수집 기술

분산 컴퓨팅 인프라 구성, 머신러닝 알고리즘 설계 등은 데이터 분석가의 기술적 하드 스킬(Hard Skill)입니다.

9번 정답: ③ 1 ZB (Zettabyte) = 1024 YB

용량 단위는 TB -> PB -> EB -> ZB -> YB 순서입니다. 따라서 1 YB = 1024 ZB이며, ③번은 반대로 쓰여 틀렸습니다.

10번 정답: ④ 플랫폼(Platform)

빅데이터가 다양한 서드파티 개발자/사업자에게 융합 서비스를 가능케 해주는 생태계 기반 역할을 하는 것을 비유하여 플랫폼(Platform)이라고 부릅니다.

[제2과목: 데이터 분석 기획]

11번 정답: ③ 통찰 (Insight)

대상(What)은 모르지만 방법(How)은 확실할 때, 기존 기법을 적용해 숨겨진 의미를 발굴하는 것은 통찰(Insight)입니다.

12번 정답: ④ 솔루션 인프라 (Solution Infrastructure)

비즈니스 모델 기반 5대 탐색 영역은 업무(Operation), 제품(Product), 고객(Customer), 규제/환경, 경쟁사/거시시장입니다. 솔루션 인프라는 이 탐색 영역 이름이 아닙니다.

13번 정답: ② 해결해야 할 문제가 무엇인지 아직 불명확하여, 보유한 대규모 데이터를 탐색적으로 파헤쳐(EDA) 새로운 패턴을 도출하고자 할 경우

문제 자체가 불명확하여 하향식 기획이 불가능할 때, 데이터를 먼저 탐색하며 귀납적으로 힌트를 얻는 것이 상향식 접근법입니다.

14번 정답: ③ 전개 (Deployment)

완성된 모델을 실제 비즈니스 프로세스 시스템에 올리고 유지보수를 진행하는 마지막 단계는 전개(Deployment)입니다.

15번 정답: ③ 포트폴리오 사분면 분석에서 1순위로 추진해야 할 과제는 '시급성이 높고 난이도는 쉬운' 과제이다.

마스터 플랜 우선순위의 가장 1순위 베스트 영역은 시급성이 높고(즉시 성과가 남) 난이도는 쉬운(빠르게 적용 가능) 사분면입니다.

16번 정답: ② 정착형

인프라/준비도 점수는 형편없으나, 일선 부서에서 분석 프로세스를 일부 사용해 성숙도 점수만 편중되어
높게 측정된 유형은 정착형입니다.

17번 정답: ① 원칙(Principle), 조직(Organization), 프로세스(Process)

전사적 통제를 위한 데이터 거버넌스 프레임워크 3대 축은 원칙(Principle), 조직(Organization),
프로세스(Process)입니다.

18번 정답: ③ 기능 중심형 조직 (Functional)

전담 조직 없이 각자의 현업 부서 내 분석 인력이 각개전투로 업무를 수행하는 것은 기능 중심형
조직입니다.

19번 정답: ④ 최종 배포될 머신러닝 앙상블 모델의 구체적인 하이퍼파라미터 수치

분석 과제 정의서는 프로젝트 착수 단계의 문서이므로, 아직 개발되지도 않은 모델의 상세 알고리즘
수치(하이퍼파라미터)를 적을 수 없습니다.

20번 정답: ④ 분석가 연봉 예산 (Analyst Salary Budget)

5대 분석 속성(5 Key Attributes)은 데이터 양(Size), 복잡도(Complexity), 속도(Speed), 분석
복잡도(Analytic Complexity), 정확/정밀도(Accuracy & Precision)입니다. 연봉 예산은 무관합니다.

[제3과목: 데이터 분석]

21번 정답: ③ 등간척도

서열 관계가 있고 사칙연산(덧셈/뺄셈)이 가능하지만, 절대 영점(0)이 없어 비율을 논할 수 없는 척도(예:
온도, 지능지수)는 등간척도(Interval Scale)입니다.

22번 정답: ② 2.0σ

결측치 대신 집단의 평균(Mean)을 채워 넣으면, 데이터들이 중앙으로 조밀하게 밀집하므로 흩어진 정도인
분산(Variance)은 과대가 아니라 과소 추정됩니다.

23번 정답: ③ -5 ~ 75

$$IQR = Q3(45) - Q1(25) = 20$$

하한선 = $Q1 - 1.5 \times IQR = 25 - 30 = -5$
상한선 = $Q3 + 1.5 \times IQR = 45 + 30 = 75$
* 따라서 -5 ~ 75 구역이 정상 범위입니다.

24번 정답: ② 제2종 오류

대립가설이 참(즉, 귀무가설 거짓)인데도 귀무가설을 기각하지 못하는(채택하는) 통계 오류는 제2종 오류(β)입니다.

25번 정답: ② 중심극한정리 (Central Limit Theorem)

모집단의 고유 모양에 구애받지 않고 표본 크기 n 이 충분히 크면 표본 평균이 정규분포를 따른다는 기적의 원리는 중심극한정리입니다.

26번 정답: ② 집락추출법 (Cluster Sampling)

군집(학급 등)을 나눈 뒤 일부 군집만 골라서 그 안을 전수조사하는 방식은 집락추출법(Cluster Sampling)입니다.

27번 정답: ② $r = 0$ 이 도출되면 두 변수 간에는 어떠한 2차, 3차 곡선 형태의 비선형 관계도 존재하지 않는다.

피어슨 상관계수가 0이면 선형(직선) 관계가 없을 뿐, 2차 곡선 등의 비선형 관계는 여전히 뚜렷할 수 있습니다.

28번 정답: ③ 등분산성 (Homoscedasticity)

독립변수 전 구간에 걸쳐 잔차의 퍼짐 정도(분산)가 깔때기처럼 변하지 않고 상수로 고르게 유지되어야 한다는 가정은 등분산성(Homoscedasticity)입니다.

29번 정답: ③ 30

$MSE = SSE / df = 200 / 20 = 10$
 $MSR = SSR / df = 600 / 2 = 300$
 $F\text{-값} = MSR / MSE = 300 / 10 = 30$ 입니다.

30번 정답: ② 분산팽창요인 (VIF)

다중공선성(Multicollinearity)의 심각도를 진단하는 전용 척도는 분산팽창요인(VIF)입니다.

31번 정답: ③ 단계별 선택법

절편만 있는 상태에서 시작해 좋은 변수를 추가하는 알고리즘은 전진 선택법입니다.

32번 정답: ③ 0.75

$Odds = p / (1-p) = 3$ 이면, $p = 3 \times (1-p) \rightarrow p = 3 - 3p \rightarrow 4p = 3 \rightarrow p = 0.75$ 입니다.

33번 정답: ④ 로그 변환 (Log Transformation)

시계열 분석 시 분산이 커지는 이분산성 문제는 로그 변환으로 잡고, 평균이 상승하는 추세 비정상성은 차분으로 잡습니다.

34번 정답: ④ d: 모형의 독립변수 간의 상관성을 뜻하는 다중공선성 차수

ARIMA의 파라미터는 p(AR 차수), d(차분 횟수), q(MA 차수)입니다. 다중공선성과는 전혀 무관합니다.

35번 정답: ② 엔트로피 지수 (Entropy Index)

정보 이론 기반으로 50:50으로 완전히 섞여 가장 혼탁할 때 1, 단일 범주일 때 0이 되는 의사결정나무 불순도 지표는 엔트로피 지수입니다.

36번 정답: ② 0.42

$Gini = 1 - (30/100)^2 - (70/100)^2 = 1 - 0.09 - 0.49 = 0.42$ 입니다.

37번 정답: ② 하이퍼볼릭 탄젠트 함수 (Tanh)

시그모이드가 [0, 1]이라 중심이 0.5로 치우치는 문제를 해소하기 위해, 중심을 0으로 맞추고 출력값을 [-1, 1]로 변환해 주는 함수는 하이퍼볼릭 탄젠트(Tanh)입니다.

38번 정답: ② 역전파 알고리즘 (Backpropagation)

출력 오차를 뒤에서부터 역으로 전파하며 미분으로 가중치를 업데이트하는 딥러닝 핵심 엔진은 역전파 알고리즘입니다.

39번 정답: ④ 랜덤 포레스트 (Random Forest)

배깅 + 변수 무작위 추출(Random Feature Subset)을 결합해 나무들 간의 상관관계를 끊고 숲의 분산을 대폭 낮춘 모델은 랜덤 포레스트입니다.

40번 정답: ① 0.20

거짓 긍정률(FPR) = $FP / (FP + TN) = 20 / (20 + 80) = 20 / 100 = 0.20$ 입니다.

41번 정답: ③ 곡선 아래 면적을 뜻하는 AUC(Area Under Curve) 값이 1에 가까울수록 모델 성능이 뛰어나다.

ROC 곡선 아래 면적인 AUC 값이 1.0에 가까울수록 가장 이상적이고 우수한 분류 성능을 갖춘 모델입니다.

42번 정답: ④ 로지스틱 회귀분석

로지스틱 회귀분석은 성공/실패라는 정답(Target Y)이 주어져 있는 대표적인 지도 학습(Supervised) 기법입니다.

43번 정답: ③ 거리 연산이 불가능한 순수 범주형(명목형) 데이터 텍스트만 주어져도 아무런 전처리 변환 없이 즉각 완벽히 분류해 낸다.

K-means는 평균 위치를 거리로 계산하므로, 유클리디안 공간 수치 연산이 불가능한 범주형/명목형 데이터는 원-핫 인코딩 등의 전처리가 없으면 즉시 적용할 수 없습니다.

44번 정답: ③ 평균 연결법 (Average Linkage)

가능한 모든 쌍의 거리를 구한 후, 그 거리들의 산술 평균을 척도로 삼는 것은 평균 연결법입니다.

45번 정답: ③ 3개

목표 설명력이 80%이므로, 누적 분산 설명률 열을 보면 PC1~PC3까지 합치면 82%가 되어 80%를 돌파합니다. 따라서 최소 3개의 주성분이 필요합니다.

46번 정답: ① 다차원척도법 (MDS)

고차원의 객체 간 유사도 거리를 계산해 2차원 평면에 맵핑(점 찍기)하여 시각화하는 차원 축소 기법은 다차원척도법(MDS)입니다.

47번 정답: ② 0.25 (50/200)

신뢰도(Confidence) = $P(Y|X) = X \text{와 } Y \text{ 동시 구매} / X \text{ 구매} = 50 / 200 = 0.25$ 입니다.

48번 정답: ③ Apriori 알고리즘

최소 지지도를 넘지 못하는 품목 조합은 그 상위 확장을 쿨하게 가지치기해 버림으로써 연산량을 폭발적으로 감소시킨 고전 알고리즘은 Apriori 알고리즘입니다.

49번 정답: ③ 훈련에 전혀 노출되지 않은 데이터를 사용하여 최종 확정된 모델의 미래 실제 일반화 예측 성능을 객관적으로 평가하는 용도

검증용(Validation)은 학습 중 하이퍼파라미터 튜닝을 위한 모니터링용이고, 학습에 아예 쓰지 않고 실배포 전 일반화 성능만 객관 평가하는 것은 평가용(Test) 데이터입니다.

50번 정답: ② 층화추출법 (Stratified Sampling)

모집단을 동질적인 여러 개의 층(학년별 등)으로 나누고 모든 층에서 각각 골고루 임의 추출하는 기법은 층화추출법(Stratified Sampling)입니다.
