

1. 다음 중 DIKW 피라미드 모델에 대한 설명으로 가장 옳바르지 않은 것은?

- ① 데이터(Data)는 객관적 사실로 가공되지 않은 순수한 수치나 기호를 의미한다.
- ② 정보(Information)는 데이터의 가공 및 상관관계 간 이해를 통해 패턴을 인식하고 의미를 부여한 것이다.
- ③ 지식(Knowledge)은 상호 연결된 정보 패턴을 이해하여 이를 토대로 예측한 결과물이다.
- ④ "A마트의 연필이 100원이고 B마트는 200원이다"라는 사실은 지혜(Wisdom)에 해당한다.

2. 빅데이터의 가치 산정이 특히 어려운 본질적인 이유로 가장 거리가 먼 것은?

- ① 데이터의 다목적용 특성으로 인해 누가 언제 사용했는지 추적하기 어렵기 때문이다.
- ② 기존에는 없던 새로운 비즈니스적 가치를 창출하기 때문이다.
- ③ 분석 기술의 발전으로 과거엔 분석 불가능했던 데이터도 새로운 가치를 지니게 되기 때문이다.
- ④ 데이터 사이언티스트들의 역량이 상향 평준화되어 모든 기업이 동일한 분석 결과를 내기 때문이다.

3. 데이터베이스(DB)의 일반적인 4가지 특성 중 "데이터베이스에 저장된 데이터는 다수의 사용자가 서로 다른 목적으로 동시에 접근하여 공동으로 이용할 수 있다"는 의미를 뜻하는 속성은?

- ① 통합 데이터 (Integrated Data)
- ② 저장 데이터 (Stored Data)
- ③ 공용 데이터 (Shared Data)
- ④ 운영 데이터 (Operational Data)

4. 기업의 내부 데이터베이스 솔루션 중 실시간으로 발생하는 대규모 거래 데이터를 빈번하게 삽입, 수정, 삭제하며 무결성을 유지하는 정보 시스템은?

- ① OLAP
- ② OLTP
- ③ 데이터 웨어하우스 (DW)
- ④ CRM

5. 지식경영의 SECI 모델에서 "조직 구성원들이 각자의 암묵지(Tacit Knowledge)를 문서, 매뉴얼, 공식 지침 등 외부에서 인식 가능한 형태(Explicit Knowledge)로 전환하는 과정"은?

- ① 공통화 (Socialization)
 - ② 표출화 (Externalization)
 - ③ 연결화 (Combination)
 - ④ 내면화 (Internalization)
-

6. 빅데이터 시대의 위기 요인 중 '책임 원칙 훼손(Accountability Principle)' 현상을 방지하기 위해 제시되는 가장 적절한 통제 방안은?

- ① 정보 수집 시 사전 동의제 강화
 - ② 알고리즘 접근권 허용 및 객관적 인증 방안 도입
 - ③ 결과 기반 책임제로의 전면 전환
 - ④ 익명화 및 가명 처리 기술 의무화
-

7. 데이터 단위 중 1 페타바이트(PB)의 1024배에 해당하는 데이터 용량 단위는?

- ① 테라바이트 (TB)
 - ② 요타바이트 (YB)
 - ③ 제타바이트 (ZB)
 - ④ 엑사바이트 (EB)
-

8. 데이터 사이언티스트에게 요구되는 역량 중 '소프트 스킬(Soft Skill)'에 해당하는 것은?

- ① 머신러닝 모형 설계 및 평가
 - ② 최적화 알고리즘 프로그래밍 코드 작성
 - ③ 데이터 시각화를 통한 스토리텔링 및 프레젠테이션
 - ④ 분산 컴퓨팅 환경 데이터베이스 구축
-

9. 다음 중 빅데이터 활용의 3대 핵심 기본 요소(3대 축)에 해당하지 않는 것은?

- ① 데이터 (Data)
 - ② 프로세스 (Process)
 - ③ 기술 (Technology)
 - ④ 인력 (People)
-

10. 비식별화 기술 중 "구체적인 데이터 값을 '30대', '서울 거주'와 같이 포괄적인 집단 값으로 변환하여 개인 식별을 방지하는 기술"은?

- ① 가명처리
- ② 총계처리

- ③ 범주화
 - ④ 데이터 마스킹
-

[제2과목: 데이터 분석 기획]

11. 분석 과제 도출 방법론 중 "기업의 구체적인 비즈니스 문제 대상(What)은 명확히 정의되어 있으나, 이를 해결하기 위한 구체적인 분석 방법(How)을 모를 때" 적용하는 기획 유형은?

- ① 최적화 (Optimization)
 - ② 솔루션 (Solution)
 - ③ 통찰 (Insight)
 - ④ 발견 (Discovery)
-

12. 하향식 접근법(Top-down Approach)의 분석 과제 도출 4단계를 순서대로 올바르게 나열한 것은?

- ① 문제 탐색 -> 문제 정의 -> 해결방안 탐색 -> 타당성 검토
 - ② 문제 정의 -> 문제 탐색 -> 타당성 검토 -> 해결방안 탐색
 - ③ 타당성 검토 -> 문제 탐색 -> 문제 정의 -> 해결방안 탐색
 - ④ 해결방안 탐색 -> 문제 정의 -> 타당성 검토 -> 문제 탐색
-

13. 상향식 접근법(Bottom-up Approach)의 주요 특징으로 가장 적절한 것은?

- ① 인과관계 규명이 분석의 최우선 목적이다.
 - ② 사전에 완벽한 가설을 수립해야만 분석이 가능하다.
 - ③ 데이터를 탐색하고 실험하는 과정에서 비즈니스 통찰을 얻는 프로토타이핑 방식을 쓴다.
 - ④ 분석의 대상과 문제가 명확할 때 가장 효율적인 방식이다.
-

14. CRISP-DM 방법론 중 "분석에 필요한 데이터를 정제(Cleaning), 통합(Integration), 포매팅(Formatting)하여 최종 분석용 데이터 세트를 편성하는 단계"는?

- ① 업무 이해 (Business Understanding)
 - ② 데이터 이해 (Data Understanding)
 - ③ 데이터 준비 (Data Preparation)
 - ④ 모델링 (Modeling)
-

15. 데이터 분석 마스터 플랜 수립 시 우선순위를 평가하는 두 가지 핵심 축 중 '난이도(Difficulty)'를 평가하는 세부 기준 요소에 해당하는 것은?

- ① 전략적 중요도
 - ② 투자 대비 효과(ROI)의 재무적 가치
 - ③ 데이터 확보 가능성 및 분석 기술 적용 수준
 - ④ 비즈니스 성과 창출 기여도
-

16. 데이터 분석 거버넌스(Data Governance)를 확립하기 위한 3대 핵심 구성 요소에 속하지 않는 것은?

- ① 데이터 표준 및 관리 원칙 (Principle)
 - ② 데이터 분석 전담 조직 (Organization)
 - ③ 품질 점검 및 운용 프로세스 (Process)
 - ④ 실시간 빅데이터 시각화 도구 (Tool)
-

17. 데이터 분석 성숙도 모델(CMMI 기반) 진단 결과, "전사적으로 데이터 분석이 프로세스에 내재화되어 있으며, 모든 부서가 자율적으로 분석을 수행하고 협업하는 성숙 단계"는?

- ① 도입 단계
 - ② 활용 단계
 - ③ 확산 단계
 - ④ 최적화 단계
-

18. 조직 내 데이터 분석 인력의 구성 방식 중 "전사 차원의 독립된 별도 전담 조직을 구성하여, 회사의 우선순위에 따라 분석 과제를 일괄적이고 통합적으로 제어 수행하는 조직 유형"은?

- ① 집중형 조직
 - ② 기능 중심형 조직
 - ③ 분산형 조직
 - ④ 매트릭스형 조직
-

19. 분석 기획 단계에서 작성하는 '분석 과제 정의서'에 반드시 포함되어야 할 항목으로 가장 거리가 먼 것은?

- ① 해결하고자 하는 비즈니스 과제 목표 및 범위
 - ② 분석에 필요한 소스 데이터와 확보 방안
 - ③ 과제 수행을 통해 예상되는 현업 실무 적용 방안 및 기대 효과
 - ④ 최종 모델에 적용될 인공지능경망의 초기 가중치(Weight) 파라미터 값
-

20. 분석 기획 시 고려해야 할 5가지 주요 요소 중, "분석 모델이 예측을 반복 실행했을 때 결과값들의 편차가 적고 일관되게 나타나는 성질"을 뜻하는 용어는?

- ① 정확도 (Accuracy)
- ② 정밀도 (Precision)
- ③ 재현율 (Recall)
- ④ 향상도 (Lift)

[제3과목: 데이터 분석]

21. "절대적인 영점(0)이 존재하여 데이터 간의 덧셈, 뺄셈뿐만 아니라 곱셈과 나눗셈 비율 연산까지 모두 유효한 척도"는 무엇인가?

- ① 명목척도 (Nominal Scale)
- ② 서열척도 (Ordinal Scale)
- ③ 등간척도 (Interval Scale)
- ④ 비율척도 (Ratio Scale)

22. 데이터 전처리 시 결측치(Missing Value)의 대체(Imputation) 방법에 대한 설명으로 옳바르지 않은 것은?

- ① 결측치를 무조건 숫자 '0'으로 일괄 대체하면 통계적 편향(Bias)이 발생한다.
- ② 단순 삭제 방식(Complete Case Analysis)은 데이터 손실을 유발하여 검정력을 떨어뜨릴 수 있다.
- ③ 평균 대체(Mean Imputation)를 적용하면 데이터의 분산(Variance)이 과대 추정되는 치명적 단점이 있다.
- ④ 회귀 대치는 다른 변수들과의 관계를 이용해 결측치를 합리적으로 예측하여 채우는 방법이다.

23. 다음 표는 어떤 연속형 데이터의 사분위수(Quartiles) 정보를 요약한 것이다.

상자그림(Boxplot) 기준, 이상치(Outlier)를 판별하는 상한 임계치(Upper Fence) 값은 얼마인가?

지 표	수 치
제3사분위수 (Q3)	20
중앙값 (Q2)	12
제1사분위수 (Q1)	8

- ① 32
- ② 38

③ 40

④ 44

24. "실제로는 대립가설이 참인데도 불구하고, 검정 결과 귀무가설을 기각하지 못하고 잘못 채택하게 되는 통계적 오류"는?

- ① 제1종 오류
- ② 제2종 오류
- ③ 표본 오차
- ④ 유의 수준 초과 오차

25. p-value(유의확률)에 대한 통계학적 해석으로 가장 옳지 않은 것은?

- ① p-value가 연구자가 설정한 유의수준(α)보다 작으면 귀무가설을 기각한다.
- ② p-value가 0.01로 산출되었다면, 이는 대립가설이 참일 확률이 1%라는 의미이다.
- ③ p-value가 클수록 귀무가설을 지지하는 증거가 강해진다고 볼 수 있다.
- ④ 귀무가설이 참이라는 가정하에 검정통계량만큼 극단적인 값이 관측될 확률이다.

26. 모집단의 개체들에 일련번호를 부여한 후, 첫 번째 표본을 무작위로 추출하고 이후에는 일정한 간격(k번째마다)으로 표본을 추출하는 확률 표본추출 기법은?

- ① 단순무작위추출법
- ② 층화추출법
- ③ 집락추출법
- ④ 계통추출법

27. 중심극한정리(Central Limit Theorem)에 대한 설명으로 옳바른 것은?

- ① 모집단이 반드시 완벽한 정규분포를 따라야만 성립하는 정리이다.
- ② 표본의 크기(n)가 커질수록 모집단 자체가 점점 정규분포 형태로 변해간다.
- ③ 모집단의 분포 형태와 상관없이 표본 크기가 충분히 크면 '표본 평균의 분포'는 정규분포에 근사한다.
- ④ 비정상 시계열 데이터를 정상 시계열로 변환하는 기초 수학 정리이다.

28. 피어슨(Pearson) 선형 상관계수(r)에 대한 설명으로 가장 적절하지 않은 것은?

- ① 수치의 범위는 -1에서 1 사이이다.
- ② 상관계수 값이 0이면 두 변수 사이에 어떠한 곡선(비선형) 관계도 존재하지 않음을 보장한다.
- ③ 두 변수의 공분산을 각각의 표준편차 곱으로 나누어 산출한다.
- ④ 절댓값이 1에 가까울수록 두 변수 간의 선형 관계가 강하다.

29. 다음 표는 어느 대학교 학생들의 성별에 따른 선호하는 과일에 대한 빈도 교차표이다. 전체 학생 중 무작위로 1명을 뽑았을 때, 그 학생이 "남학생"이라는 조건하에 "사과"를 좋아할 조건부 확률은 얼마인가?

구 분	사 과	딸 기	합 계
남학생	40	60	100
여학생	20	80	100

- ① 0.20
- ② 0.40
- ③ 0.66
- ④ 0.80

30. 다중회귀분석 과정에서 독립변수들 간에 강한 선형 상관관계가 존재하여 회귀계수 추정의 분산이 비정상적으로 커지고 모형이 불안정해지는 문제는?

- ① 다중공선성 (Multicollinearity)
- ② 등분산성 위반
- ③ 잔차의 자기상관
- ④ 정규성 결여

31. 단순선형회귀분석 적합 후 도출된 분산분석표(ANOVA)의 일부가 다음과 같다. 이 회귀모형의 설명력을 나타내는 결정계수(R2) 값은 얼마인가?

요인 (Source)	제곱합 (Sum of Squares)
회귀 (Regression, SSR)	300
잔차 (Error, SSE)	200
합계 (Total, SST)	500

- ① 0.40
- ② 0.60
- ③ 0.67
- ④ 1.50

32. 다중회귀분석의 변수 선택 기법 중 "초기 모형에 예측 변수가 하나도 없는 상태에서 출발하여, 타깃 변수 예측에 가장 기여도가 높은 유의한 변수를 하나씩 순차적으로 추가하는 방식"은?

- ① 후진 제거법 (Backward Elimination)
- ② 단계별 선택법 (Stepwise Selection)
- ③ 전진 선택법 (Forward Selection)
- ④ 전체 부분집합 탐색법

33. 로지스틱 회귀분석(Logistic Regression)에 대한 설명으로 옳바르지 않은 것은?

- ① 종속변수가 수치형 실수가 아닌 이진 범주형(예: 성공/실패)일 때 적용한다.
- ② 예측 대상인 확률 p값은 0과 1 사이로 제한되므로, 이를 실수 전체 범위로 치환하기 위해 로짓(Logit) 변환을 사용한다.
- ③ 오즈(Odds)는 사건이 '발생하지 않을 확률'을 '발생할 확률'로 나눈 수치이다.
- ④ 시그모이드(Sigmoid) 함수를 통해 선형 결합 결과를 0~1 사이의 확률로 출력한다.

34. 다음 표는 이진 분류 예측 모델의 혼동행렬(Confusion Matrix)이다. 이 모델의 정밀도(Precision) 값은 얼마인가?

실제 / 예측	참(True)으로 예측	거짓(False)으로 예측
실제 참(True)	80 (TP)	20 (FN)
실제 거짓(False)	40 (FP)	160 (TN)

- ① 0.66
- ② 0.75
- ③ 0.80
- ④ 0.88

35. 분류 모형 평가 지표 중 ROC(Receiver Operating Characteristic) 곡선에 대한 설명으로 옳바른 것은?

- ① X축에는 민감도(Sensitivity), Y축에는 정밀도(Precision)를 배치한다.
- ② 곡선 아래의 면적인 AUC(Area Under Curve) 값이 0.5에 가까울수록 분류 성능이 우수한 모델이다.
- ③ X축에는 거짓 긍정률(1-특이도), Y축에는 진짜 긍정률(민감도)을 배치한다.
- ④ ROC 곡선은 데이터가 심하게 불균형할 때만 예외적으로 그릴 수 있다.

36. 비정상 시계열 데이터를 정상 시계열로 변환할 때, 시간에 따라 '평균'이 일정하지 않고 상승하는 추세(Trend)를 제거하기 위한 가장 표준적인 방법은?

- ① 로그 변환 (Log Transformation)

- ② 차분 (Differencing)
 - ③ 정규화 (Normalization)
 - ④ 이상치 교체
-

37. 시계열 분석 요인 중 "1년 단위 내에서 계절의 변화, 명절 등 달력과 같이 고정된 주기를 가지며 상하 반복되는 규칙적인 변동"은?

- ① 추세 요인 (Trend)
 - ② 계절 요인 (Seasonal)
 - ③ 순환 요인 (Cyclical)
 - ④ 불규칙 요인 (Irregular)
-

38. 분류 분석을 위한 의사결정나무(Decision Tree) 모델에서 마디를 분할할 때 순수도(Purity)를 평가하는 지표로 적합하지 않은 것은?

- ① 카이제곱 통계량 (p-value)
 - ② 엔트로피 지수 (Entropy Index)
 - ③ 지니 지수 (Gini Index)
 - ④ 잔차제곱합 (SSE)
-

39. 인공지능망 다층 퍼셉트론 모형에서 기울기 소실(Vanishing Gradient) 문제를 해결하기 위해, 입력값이 0보다 작으면 0을 반환하고 0 이상이면 선형값 그대로 출력하는 은닉층 활성화 함수는?

- ① 소프트맥스 함수 (Softmax)
 - ② 하이퍼볼릭 탄젠트 함수 (Tanh)
 - ③ 렐루 함수 (ReLU)
 - ④ 시그모이드 함수 (Sigmoid)
-

40. 앙상블 기법 중 "원본 데이터로부터 복원 추출 방식의 부트스트랩(Bootstrap) 샘플을 여러 개 독립 생성하고, 각 샘플마다 개별 약한 나무 모델들을 병렬로 동시에 학습시킨 후 결과를 다수결 투표(Voting)로 합치는 방식"은?

- ① 배깅 (Bagging)
 - ② 부스팅 (Boosting)
 - ③ 스택킹 (Stacking)
 - ④ K-NN 모델링
-

41. 다음 중 비지도 학습(Unsupervised Learning)에 속하는 데이터 마이닝 기법으로 짝지어진 것은?

- ① K-means 군집분석, 로지스틱 회귀분석
- ② 의사결정나무, 주성분 분석(PCA)
- ③ K-means 군집분석, 연관규칙분석(Apriori)
- ④ 인공신경망, 서포트 벡터 머신(SVM)

42. 다음 주성분 분석(PCA) 결과표(Eigenvalues)를 참고하여 카이저(Kaiser) 준칙에 따라 최적의 주성분 개수를 선택하고자 한다. 선택해야 할 주성분의 개수는?

주성분 (PC)	고윳값 (Eigenvalue)
PC1	2.9
PC2	1.4
PC3	0.8
PC4	0.5

- ① 1개
- ② 2개
- ③ 3개
- ④ 4개

43. 계층적 군집분석에서 두 군집 간의 거리를 판별할 때 "두 군집 내 모든 개체 조합 쌍의 거리를 전부 연산한 후, 그중 가장 먼 거리(최댓값)를 두 군집 간의 거리로 정의하여 묶어가는 방식"은?

- ① 단일 연결법 (Single Linkage)
- ② 평균 연결법 (Average Linkage)
- ③ 중심 연결법 (Centroid Linkage)
- ④ 완전 연결법 (Complete Linkage)

44. 장바구니 연관규칙분석에서 품목 간 거래 건수를 조사한 결과가 아래와 같다. 규칙 A->B의 향상도(Lift) 값을 구하시오. 총 거래 건수: 100건 / 품목 A 구매: 40건 / 품목 B 구매: 50건 / A와 B 동시 구매: 20건

- ① 0.5
- ② 1.0
- ③ 1.5
- ④ 2.0

45. "최소 지지도(Minimum Support)를 설정한 후, 이를 넘지 못하는 품목 집합을 하향식으로 조기 차단(가지치기)하여 연산량을 획기적으로 줄여주는 알고리즘"은?

- ① DBSCAN
 - ② Apriori
 - ③ EM 알고리즘
 - ④ K-means
-

46. "군집 내 데이터들은 얼마나 조밀하게 응집되어 있는지, 그리고 다른 군집과는 얼마나 확실히 떨어져 분리되어 있는지를 결합 연산하여 -1~1 사이의 값으로 군집화 타당성을 평가하는 지표"는?

- ① 유클리드 거리 지수
 - ② 스트레스 값 (Stress)
 - ③ 실루엣 계수 (Silhouette Coefficient)
 - ④ 다중공선성 지표 (VIF)
-

47. 신경망 모형에서 출력층의 예측 목표가 '다중 범주 분류(3개 이상의 클래스)'일 때, 각 노드의 출력값을 확률 형태로 변환하여 총합이 항상 1이 되도록 제어해 주는 함수는?

- ① 소프트맥스 함수 (Softmax)
 - ② 렐루 함수 (ReLU)
 - ③ 가우스 혼합 함수
 - ④ 스텝 함수 (Step Function)
-

48. 의사결정나무 모델이 학습 데이터에만 과도하게 최적화되어 깊게 성장하는 과적합(Overfitting)을 방지하기 위해, 하단부의 불필요한 분기 마디를 사후에 잘라내어 모형의 일반화 성능을 높이는 제어 기법은?

- ① 라쏘 제어 (Lasso)
 - ② 차원 축소 (Dimension Reduction)
 - ③ 가지치기 (Pruning)
 - ④ 보팅 (Voting)
-

49. 군집의 특성 차이를 비교 분석할 때, 변수 간의 분산 및 공분산 구조를 동시에 반영하여 스케일에 구애받지 않게 계산하는 다변량 통계 거리는?

- ① 맨하탄 거리 (Manhattan Distance)
- ② 마할라노비스 거리 (Mahalanobis Distance)
- ③ 자카드 거리 (Jaccard Distance)

50. 앙상블 학습 기법 중 하나인 '랜덤 포레스트(Random Forest)'의 핵심 원리 특징으로 가장 거리가 먼 것은?

- ① 배깅(Bagging)의 기본 메커니즘인 부트스트래핑 복원 추출 샘플링을 수행한다.
 - ② 각 나무 노드를 분할할 때 모든 독립변수를 검토하지 않고 무작위로 선택된 일부 변수 부분집합(Random Feature Subset)만 사용한다.
 - ③ 이를 통해 개별 나무 모형들 간의 상관관계를 낮추어 숲 전체의 분산을 크게 감소시킨다.
 - ④ 이전 나무 모델이 잘못 예측한 오차(잔차)를 다음 나무 모델이 순차적으로 집중 학습하여 보정해 나가는 경사하강 구조를 취한다.
-

제1회 ADsP AI 모의고사

번호	정답	번호	정답	번호	정답	번호	정답	번호	정답
1	④	11	②	21	④	31	②	41	③
2	④	12	①	22	③	32	③	42	②
3	③	13	③	23	②	33	③	43	④
4	②	14	③	24	②	34	①	44	②
5	②	15	③	25	②	35	③	45	②
6	②	16	④	26	④	36	②	46	③
7	④	17	③	27	③	37	②	47	①
8	③	18	①	28	②	38	④	48	③
9	②	19	④	29	②	39	③	49	②
10	③	20	②	30	①	40	①	50	④

제1회 ADsP AI 모의고사

[제1과목: 데이터 이해]

1번 정답: ④ "A마트의 연필이 100원이고 B마트는 200원이다"라는 사실은 지혜(Wisdom)에 해당한다.

마트 가격 비교는 정보(Information) 단계입니다. "어디서 사야겠다"는 결론이 지식, 더 나아가 본질적 통찰을 이끌어내면 지혜(Wisdom)입니다.

2번 정답: ④ 데이터 사이언티스트들의 역량이 상향 평준화되어 모든 기업이 동일한 분석 결과를 내기 때문이다.

가치 산정이 어려운 이유는 데이터의 다목적 활용성과 새로운 가치 창출성 때문입니다. 분석 역량의 평준화는 본질적인 이유가 아닙니다.

3번 정답: ③ 공용 데이터 (Shared Data)

여러 사용자가 동시에 접근하여 공동으로 이용할 수 있는 특징은 공용 데이터(Shared Data)입니다.

4번 정답: ② OLTP

실시간 갱신 및 무결성 처리는 OLTP(Online Transaction Processing)입니다. OLAP은 분석용, DW는 저장소입니다.

5번 정답: ② 표출화 (Externalization)

개인의 암묵지(머릿속 노하우)를 글이나 매뉴얼 등 형식지(Explicit Knowledge)로 꺼내는 과정은 표출화(Externalization)입니다.

6번 정답: ② 알고리즘 접근권 허용 및 객관적 인증 방안 도입

알고리즘 맹신에 따른 책임 원칙 훼손을 막기 위해, 알고리즘 작동 원리를 들여다볼 수 있는 알고리즘 접근권이 대안으로 제시됩니다.

7번 정답: ④ 엑사바이트 (EB)

데이터 단위는 TB(테라) -> PB(페타) -> EB(엑사) -> ZB(제타) -> YB(요타) 순으로 1024배씩 커집니다. PB의 1024배는 EB입니다.

8번 정답: ③ 데이터 시각화를 통한 스토리텔링 및 프레젠테이션

시각화, 스토리텔링, 의사소통 역량은 소프트 스킬입니다. 수학 및 코딩 능력은 하드 스킬에 해당합니다.

9번 정답: ② 프로세스 (Process)

빅데이터 3대 핵심 요소는 데이터(Data), 기술(Technology), 인력(People)입니다. 프로세스는 3대 축 명칭에 포함되지 않습니다.

10번 정답: ③ 범주화

구체적 값을 '30대', '서울 거주'처럼 넓은 구간으로 묶어 식별을 방지하는 기술은 범주화입니다.

[제2과목: 데이터 분석 기획]

11번 정답: ② 솔루션 (Solution)

대상(What)은 알지만 기법(How)을 모를 때는 솔루션(Solution) 방향으로 기획합니다.

12번 정답: ① 문제 탐색 -> 문제 정의 -> 해결방안 탐색 -> 타당성 검토

하향식 기획은 [문제 탐색] -> [문제 정의] -> [해결방안 탐색] -> [타당성 검토] 순서입니다.

13번 정답: ③ 데이터를 탐색하고 실험하는 과정에서 비즈니스 통찰을 얻는 프로토타이핑 방식을 쓴다.

상향식은 비정형 환경에서 데이터를 탐색하며 점진적으로 문제를 파악하는 프로토타이핑 방식을 씁니다.

14번 정답: ③ 데이터 준비 (Data Preparation)

데이터를 통합하고 변수를 편성하는 물리적 전처리 단계는 데이터 준비(Data Preparation)입니다.

15번 정답: ③ 데이터 확보 가능성 및 분석 기술 적용 수준

데이터 획득 어려움, 기술 복잡도, 인력 수준은 수행 난이도 평가 축의 기준 요소입니다.

16번 정답: ④ 실시간 빅데이터 시각화 도구 (Tool)

거버넌스의 3대 구성 요소는 원칙(Principle), 조직(Organization), 프로세스(Process)입니다. 시각화 도구는 포함되지 않습니다.

17번 정답: ③ 확산 단계

전사가 자율적으로 분석에 참여하고 최적화 직전 단계에 이른 성숙도는 확산 단계입니다.

18번 정답: ① 집중형 조직

별도의 전담 조직이 일괄 통합 관리하는 구조는 집중형 조직입니다.

19번 정답: ④ 최종 모델에 적용될 인공지능망의 초기 가중치(Weight) 파라미터 값

분석 과제 정의서는 기획 단계의 개요 문서이므로, 모델 결과인 가중치 파라미터 수치를 사전에 기입할 수 없습니다.

20번 정답: ② 정밀도 (Precision)

반복 측정 시 결과값들이 퍼지지 않고 일관되게 나오는 성질은 정밀도(Precision)입니다.

[제3과목: 데이터 분석]

21번 정답: ④ 비율척도 (Ratio Scale)

절대적 영점(0)이 존재하여 비율(나눗셈) 계산이 가능한 척도는 비율척도(Ratio Scale)입니다.

22번 정답: ③ 평균 대체(Mean Imputation)를 적용하면 데이터의 분산(Variance)이 과대 추정되는 치명적 단점이 있다.

평균 대체를 하면 결측치들이 모두 중앙(평균)값으로 모이므로 분산은 오히려 과소 추정됩니다. 과대 추정이라는 설명은 틀립니다.

23번 정답: ② 38

$$IQR = Q3 - Q1 = 20 - 8 = 12$$

$$\text{Upper Fence} = Q3 + 1.5 \times IQR = 20 + 18 = 38$$

* Upper Fence를 초과하는 값이 이상치(Outlier)로 판별됩니다.

24번 정답: ② 제2종 오류

대립가설이 참(귀무가설이 거짓)인데도 귀무가설을 채택하여 범인을 놓치는 오류는 제2종 오류(베타 오류)입니다.

25번 정답: ② p-value가 0.01로 산출되었다면, 이는 대립가설이 참일 확률이 1%라는 의미이다.

p-value는 "귀무가설이 참일 때 이 데이터가 관측될 확률"이지, "대립가설이 참일 확률"을 직접 의미하지 않습니다.

26번 정답: ④ 계통추출법

번호를 부여하고 일정 간격으로 표본을 뽑아내는 방식은 계통추출법(Systematic Sampling)입니다.

27번 정답: ③ 모집단의 분포 형태와 상관없이 표본 크기가 충분히 크면 '표본 평균의 분포'는 정규분포에 근사한다.

중심극한정리: 모집단 분포와 관계없이, 표본 크기가 충분히 크면 표본 평균의 분포는 정규분포에 근사합니다.

28번 정답: ② 상관계수 값이 0이면 두 변수 사이에 어떠한 곡선(비선형) 관계도 존재하지 않음을 보장한다.

피어슨 상관계수가 0이라는 것은 선형 관계가 없다는 뜻일 뿐, 2차 함수 같은 비선형 관계는 뚜렷하게 존재할 수 있습니다.

29번 정답: ② 0.40

분모: 남학생 전체 = 100명

분자: 남학생 중 사과를 좋아하는 수 = 40명

조건부 확률 = $40 / 100 = 0.40$

30번 정답: ① 다중공선성 (Multicollinearity)

독립변수들 간에 강한 선형 상관관계가 존재하여 모델을 불안정하게 만드는 문제는 다중공선성(Multicollinearity)입니다.

31번 정답: ② 0.60

$R^2 = SSR / SST = 300 / 500 = 0.60$

* $R^2 = 0.60$ 이란, 회귀모형이 종속변수 변동의 60%를 설명한다는 의미입니다.

32번 정답: ③ 전진 선택법 (Forward Selection)

아무것도 없는 상태에서 기여도 높은 변수를 하나씩 추가하는 방식은 전진 선택법(Forward Selection)입니다.

33번 정답: ③ 오즈(Odds)는 사건이 '발생하지 않을 확률'을 '발생할 확률'로 나눈 수치이다.

오즈(Odds) = 발생할 확률 / 발생하지 않을 확률 = $p / (1-p)$ 입니다. 보기 ③은 분자와 분모가 뒤바뀐 잘못된 설명입니다.

34번 정답: ① 0.66

$\text{Precision} = \text{TP} / (\text{TP} + \text{FP}) = 80 / (80 + 40) = 80 / 120 = 0.667$ (약 0.66)

35번 정답: ③ X축에는 거짓 긍정률(1-특이도), Y축에는 진짜 긍정률(민감도)을 배치한다.

ROC 곡선: X축 = 거짓 긍정률(1-특이도), Y축 = 진짜 긍정률(민감도)입니다. AUC가 1.0에 가까울수록 우수한 모델입니다.

36번 정답: ② 차분 (Differencing)

평균의 추세 변동을 제거하기 위해 직전 시점 값을 빼주는 연산은 차분(Differencing)입니다.

37번 정답: ② 계절 요인 (Seasonal)

1년 주기로 달력이나 절기에 맞춰 상하 반복되는 규칙적 변동은 계절 요인(Seasonal)입니다.

38번 정답: ④ 잔차제곱합 (SSE)

잔차제곱합(SSE)은 범주를 가르는 분류나무가 아닌 수치를 예측하는 회귀나무(Regression Tree)의 평가 지표입니다.

39번 정답: ③ 렐루 함수 (ReLU)

0 이하는 차단하고 양수는 그대로 전달하여 기울기 소실 문제를 해결한 활성화 함수는 ReLU입니다.

40번 정답: ① 배깅 (Bagging)

부트스트랩 샘플 생성 후 병렬로 학습하고 다수결 투표로 결합하는 방식은 배깅(Bagging)입니다.

41번 정답: ③ K-means 군집분석, 연관규칙분석(Apriori)

K-means 군집분석과 Apriori 연관분석은 정답 레이블(Y)이 필요 없는 비지도 학습입니다.

42번 정답: ② 2개

카이저 준칙: 고유값(Eigenvalue)이 1.0 이상인 주성분만 선택합니다.
PC1(2.9), PC2(1.4)만 1.0 이상이므로 2개를 선택합니다.

43번 정답: ④ 완전 연결법 (Complete Linkage)

개체 쌍들의 거리 중 최댓값(가장 먼 거리)을 기준으로 삼는 방식은 완전 연결법(Complete Linkage)입니다.

44번 정답: ② 1.0

$$\text{지지도} = 20/100 = 0.20$$

$$P(A) \times P(B) = (40/100) \times (50/100) = 0.20$$

$$\text{향상도(Lift)} = 0.20 / 0.20 = 1.0$$

* Lift = 1.0은 A와 B가 서로 완전히 독립적임을 의미합니다.

45번 정답: ② Apriori

최소 지지도 가지치기를 통해 항목 조합의 폭발을 막아주는 장바구니 알고리즘은 Apriori입니다.

46번 정답: ③ 실루엣 계수 (Silhouette Coefficient)

응집도와 분리도를 동시에 측정하여 -1~1 사이 값으로 군집화 타당성을 평가하는 지표는 실루엣 계수(Silhouette Coefficient)입니다.

47번 정답: ① 소프트맥스 함수 (Softmax)

다중 클래스 분류에서 출력 노드의 확률 합을 1로 맞춰주는 함수는 소프트맥스(Softmax)입니다.

48번 정답: ③ 가지치기 (Pruning)

나무 모형이 과적합되지 않도록 불필요한 마디를 사후에 절단하는 기법은 가지치기(Pruning)입니다.

49번 정답: ② 마할라노비스 거리 (Mahalanobis Distance)

변수 간의 분산 및 공분산 구조를 반영하여 스케일에 구애받지 않고 계산하는 거리는 마할라노비스 거리(Mahalanobis Distance)입니다.

50번 정답: ④ 이전 나무 모델이 잘못 예측한 오차(잔차)를 다음 나무 모델이 순차적으로 집중 학습하여 보정해 나가는 경사하강 구조를 취한다.

이전 나무의 오차(잔차)를 다음 나무가 순차적으로 집중 학습하는 구조는 랜덤 포레스트(배깅 계열)가 아니라 부스팅(Boosting) 계열(GBM 등)의 특징입니다.
