

[제1과목: 데이터 이해]

1. 다음 중 데이터와 정보, 지식, 지혜를 구분하는 DIKW 피라미드 모델에 대한 설명으로 가장 옳지 않은 것은?

- ① 데이터(Data)는 존재적 특성을 갖는 객관적 사실이다.
- ② 정보(Information)는 데이터의 가공 및 상관관계 간 이해를 통해 패턴을 인식하고 의미를 부여한 것이다.
- ③ 지식(Knowledge)은 상호 연결된 정보 패턴을 이해하여 이를 토대로 근본적인 원리를 도출해 낸 것이다.
- ④ "A마트의 연필 가격이 B마트보다 저렴하므로, 앞으로는 A마트에서 연필을 사야겠다"는 지혜(Wisdom)에 해당한다.

2. 기업 내부 데이터베이스 시스템 중, 기업 내의 인적 자원, 재무, 생산, 유통 등 전사적인 자원과 프로세스를 통합적으로 관리하여 경영 효율성을 높이는 시스템은 무엇인가?

- ① CRM (Customer Relationship Management)
- ② SCM (Supply Chain Management)
- ③ ERP (Enterprise Resource Planning)
- ④ OLAP (Online Analytical Processing)

3. 다음 표는 개인정보 비식별화 기술의 예시를 나타낸 것이다. 각 기술의 명칭으로 올바르게 짝지어진 것은?

구분	처리 전 (원본)	처리 후 (비식별화)
(가)	홍길동, 35세, 서울시 강남구	임꺽정, 35세, 서울시 강남구
(나)	홍길동, 35세, 서울시 강남구	홍**, 30대, 서울시 강남구

- ① (가) 가명처리, (나) 마스킹 및 범주화
- ② (가) 마스킹, (나) 총계처리
- ③ (가) 데이터 값 삭제, (나) 가명처리
- ④ (가) 범주화, (나) 데이터 무작위화

4. 데이터 사이언티스트에게 요구되는 역량 중 '소프트 스킬(Soft Skill)'에 해당하지 않는 것은?

- ① 분석 결과를 경영진이 이해하기 쉽게 전달하는 시각화 및 스토리텔링 능력
 - ② 비즈니스 트렌드를 파악하고 문제를 정의하는 인문학적 통찰력
 - ③ 다양한 부서와의 원활한 협업을 이끌어내는 커뮤니케이션 능력
 - ④ 분산 파일 시스템(Hadoop 등)을 구축하고 데이터 파이프라인을 설계하는 엔지니어링 능력
-

5. 빅데이터 시대에 접어들면서 나타난 데이터 분석 패러다임의 변화로 가장 적절하지 않은 것은?

- ① 사전처리(기획 후 수집) 방식에서 사후처리(수집 후 분석) 방식으로 변화하였다.
 - ② 표본조사(Sample) 중심에서 대규모 전수조사(Census) 중심으로 변화하였다.
 - ③ 데이터의 정밀한 질(Quality)만을 추구하던 방향에서, 대규모의 양(Quantity)을 수용하는 방향으로 변화하였다.
 - ④ 데이터 간의 뚜렷한 인과관계(Causality) 규명을 최우선으로 삼는 방향으로 완전히 정착하였다.
-

6. 지식경영의 SECI 모델에서 "개인의 암묵지(Tacit Knowledge)를 언어나 기호, 매뉴얼 등의 형태로 변환하여 타인과 공유할 수 있는 형식지(Explicit Knowledge)로 만드는 과정"은?

- ① 공통화 (Socialization)
 - ② 표출화 (Externalization)
 - ③ 연결화 (Combination)
 - ④ 내면화 (Internalization)
-

7. 빅데이터의 가치를 산정하기 어려운 이유를 설명한 것으로 가장 거리가 먼 것은?

- ① 데이터가 특정 목적뿐만 아니라 여러 가지 다양한 목적으로 재사용될 수 있기 때문이다.
 - ② 분석 기술의 발전으로 인해 기존에는 무의미했던 데이터가 새로운 통찰을 제공하기 때문이다.
 - ③ 데이터가 창출하는 가치가 사전에 예측하기 어려운 새로운 비즈니스 아이디어로 이어지기 때문이다.
 - ④ 모든 데이터가 철저히 정형화되어 있어, 분석 모델 간의 성능 차이가 발생하지 않기 때문이다.
-

8. 다음 중 빅데이터의 위기 요인인 '알고리즘에 의한 부당한 피해(책임 원칙 훼손)'를 예방하기 위해 제시되는 통제 방안은 무엇인가?

- ① 개인정보 수집 시 사전 동의제 강화
 - ② 익명화(Anonymization) 기술의 전면 도입
 - ③ 알고리즘리스트(Algorithmist) 직군 도입 및 알고리즘 접근권 허용
 - ④ 결과 기반 책임제로의 전면 전환
-

9. 데이터베이스의 일반적인 4가지 특징에 포함되지 않는 것은?

- ① 통합 데이터 (Integrated Data)

- ② 저장 데이터 (Stored Data)
- ③ 공유 데이터 (Shared Data)
- ④ 비휘발성 데이터 (Non-volatile Data)

10. 데이터 용량의 단위가 작은 것부터 큰 순서대로 올바르게 나열된 것은?

- ① 테라(TB) -> 페타(PB) -> 제타(ZB) -> 엑사(EB)
- ② 페타(PB) -> 테라(TB) -> 엑사(EB) -> 요타(YB)
- ③ 테라(TB) -> 페타(PB) -> 엑사(EB) -> 제타(ZB)
- ④ 페타(PB) -> 엑사(EB) -> 요타(YB) -> 제타(ZB)

[제2과목: 데이터 분석 기획]

11. 데이터 분석 주제 유형(Analysis Subject Type)에 대한 설명으로 올바른 것은?

- ① 최적화(Optimization): 분석 대상(What)과 분석 방법(How)을 모두 모를 때 적용한다.
- ② 솔루션(Solution): 분석 대상(What)은 알지만 분석 방법(How)을 모를 때 적용한다.
- ③ 통찰(Insight): 분석 대상(What)과 분석 방법(How)을 모두 명확히 알 때 적용한다.
- ④ 발견(Discovery): 분석 대상(What)은 모르지만 분석 방법(How)은 알 때 적용한다.

12. 하향식 접근법(Top-down Approach)의 '문제 탐색(Problem Discovery)' 단계에서 비즈니스 모델 캔버스를 활용하여 과제를 발굴할 때 고려하는 5가지 주요 영역에 해당하지 않는 것은?

- ① 업무(Operation)
- ② 제품(Product)
- ③ 고객(Customer)
- ④ 데이터 인프라(Data Infrastructure)

13. 데이터 분석 마스터 플랜 수립 시 우선순위를 결정하기 위한 평가 기준 중 '투자 대비 효과(ROI)' 관점에서 '비용(Investment, 투자비용)' 요소에 해당하는 것은?

- ① 전략적 중요도
- ② 비즈니스 성과
- ③ 실행의 시급성
- ④ 데이터 수집 및 시스템 구현 복잡도(난이도)

14. CRISP-DM 분석 방법론에서 "데이터의 특성을 파악하고, 데이터 품질 문제를 식별하며, 숨겨진 인사이트를 발견하기 위해 탐색적 데이터 분석(EDA)을 수행하는 단계"는?

- ① 업무 이해 (Business Understanding)
 - ② 데이터 이해 (Data Understanding)
 - ③ 데이터 준비 (Data Preparation)
 - ④ 모델링 (Modeling)
-

15. 데이터 분석 수준 진단 결과, 조직의 "분석 준비도(Readiness)는 낮지만, 전사적인 분석 프로세스 내재화 및 관리 체계(성숙도, Maturity)는 높게 정착된 기업"을 지칭하는 사분면 유형은?

- ① 준비형
 - ② 도입형
 - ③ 정착형
 - ④ 확산형
-

16. 데이터 거버넌스(Data Governance) 체계 구축을 위한 3대 핵심 구성 요소로 올바르게 짝지어진 것은?

- ① 원칙(Principle), 조직(Organization), 프로세스(Process)
 - ② 인력(People), 기술(Technology), 데이터(Data)
 - ③ 표준화(Standardization), 보안(Security), 메타데이터(Meta Data)
 - ④ 수집(Collection), 저장(Storage), 활용(Utilization)
-

17. 분석 과제 정의서를 작성할 때 기재해야 할 필수 항목으로 가장 거리가 먼 것은?

- ① 과제의 목적 및 해결해야 할 비즈니스 질문
 - ② 분석에 사용될 데이터 소스 및 입수 방법
 - ③ 최종적으로 적용될 딥러닝 모델의 은닉층 개수와 노드 수
 - ④ 과제 수행 후의 예상 비즈니스 효과 및 평가 지표
-

18. 데이터 분석 조직 구조 중 "별도의 전담 분석 조직을 독립적으로 구성하여, 전사의 분석 과제를 일괄적이고 통합적으로 수행 및 관리하는 조직 형태"는?

- ① 집중형 조직
 - ② 분산형 조직
 - ③ 기능 중심형 조직
 - ④ 매트릭스형 조직
-

19. 분석 프로젝트 관리를 위해 고려해야 할 5대 주요 속성(5 Key Attributes)에 해당하지 않는 것은?

- ① Data Size (데이터의 양)
- ② Data Complexity (데이터의 복잡도)
- ③ Speed (분석 속도)
- ④ Data Ownership (데이터 소유권)

20. 비정형 데이터나 새로운 비즈니스 기회를 발굴하기 위해 사전에 가설을 세우지 않고, 데이터 자체를 탐색하면서 문제를 정의해 나가는 분석 기획 방식은?

- ① 하향식 접근법 (Top-down Approach)
- ② 상향식 접근법 (Bottom-up Approach)
- ③ 폭포수 방법론 (Waterfall)
- ④ 나선형 방법론 (Spiral)

[제3과목: 데이터 분석]

21. 데이터 척도 중 "순위나 서열 정보뿐만 아니라 값들 사이의 간격(차이)이 의미를 가지며 덧셈/뺄셈 연산이 가능하지만, 절대적인 영점(0)이 없어 비율(나눗셈) 연산은 불가능한 척도"는 무엇인가?

- ① 명목척도 (Nominal Scale)
- ② 서열척도 (Ordinal Scale)
- ③ 등간척도 (Interval Scale)
- ④ 비율척도 (Ratio Scale)

22. 데이터 전처리 시 결측치(Missing Value) 처리에 대한 설명으로 옳바르지 않은 것은?

- ① 데이터에 결측치가 존재할 경우, 분석 모델이 작동하지 않거나 왜곡된 결과를 초래할 수 있다.
- ② 단순 삭제법(Listwise Deletion)은 처리하기 쉽지만 데이터의 표본 크기가 줄어드는 단점이 있다.
- ③ 평균 대체법(Mean Imputation)을 사용하면 표본 크기는 유지되지만, 해당 변수의 분산(Variance)이 과대 추정되는 문제가 발생한다.
- ④ 다중 대체법(Multiple Imputation)은 결측치를 여러 번 추정하여 불확실성을 반영하는 고급 기법이다.

23. 다음 표는 어떤 연속형 변수의 사분위수(Quartiles) 정보를 요약한 것이다.

상자그림(Boxplot)의 규칙에 따라 하한 임계치(Lower Fence)를 연산하였을 때, 그 값으로 올바른

것은?

지 표	수 치
제3사분위수 (Q3)	30
중앙값 (Q2)	22
제1사분위수 (Q1)	10

- ① -10
- ② -15
- ③ -20
- ④ 0

24. 통계적 가설검정에서 유의수준(Significance Level, α)의 정의로 가장 올바른 것은?

- ① 제2종 오류를 범할 확률의 최대 허용 한계
- ② 귀무가설이 참일 때, 이를 잘못 기각하는 제1종 오류를 범할 확률의 최대 허용 한계
- ③ 대립가설이 참일 때, 귀무가설을 올바르게 기각할 확률
- ④ 귀무가설이 참일 때, 검정통계량 이상으로 극단적인 값이 나올 확률

25. 다음 중 표본추출 방법과 그에 대한 설명이 올바르게 짝지어지지 않은 것은?

- ① 단순무작위추출: 모집단의 모든 개체가 뽑힐 확률이 동일하게 무작위로 추출한다.
- ② 계통추출: 모집단에 일련번호를 부여하고 일정한 간격(k번째)으로 추출한다.
- ③ 층화추출: 모집단을 동질적인 여러 집단으로 나누고, 특정 하나의 집단만을 무작위로 선택하여 그 안에서 전수조사한다.
- ④ 군집추출: 모집단을 이질적인 구성원을 가진 여러 군집으로 나누고, 무작위로 추출된 군집 내의 모든 개체를 조사한다.

26. 다음 표는 어느 회사의 부서별 직원의 만족도 조사 결과를 나타낸 분할표(교차표)이다. 전체 직원 중 1명을 뽑았을 때, 그 직원이 '영업부'라는 조건하에 '불만족'할 조건부 확률은 얼마인가?

구분	만족	불만족	합계
영업부	30	20	50
개발부	40	10	50
합계	70	30	100

- ① 2/3
- ② 2/5

- ③ 1/5
- ④ 3/5

27. 다음 중 스피어만 순위 상관계수(Spearman's Rank Correlation Coefficient)에 대한 설명으로 올바른 것은?

- ① 연속형 변수들 간의 선형(Linear) 관계만을 측정하기 위한 모수적 통계 지표이다.
- ② 두 변수 값 자체의 크기를 사용하여 공분산을 표준화한 값이다.
- ③ 데이터가 서열척도이거나 비선형적인 단조(Monotonic) 관계를 가질 때 적합한 비모수적 상관계수이다.
- ④ 상관계수의 범위는 0에서 무한대 사이의 값을 갖는다.

28. 선형회귀분석의 오차항(잔차)이 충족해야 하는 4가지 기본 가정에 해당하지 않는 것은?

- ① 선형성 (Linearity)
- ② 독립성 (Independence)
- ③ 등분산성 (Homoscedasticity)
- ④ 다중공선성 (Multicollinearity)

29. 단순선형회귀분석을 수행한 후 얻은 분산분석표(ANOVA)의 정보가 아래와 같을 때, 이 회귀모형의 잔차 분산을 나타내는 평균제곱오차(MSE)의 값은 얼마인가?

요인 (Source)	자유도 (df)	제곱합 (SS)
회귀 (Regression)	1	800
잔차 (Error)	18	180
총계 (Total)	19	980

- ① 10
- ② 18
- ③ 44.4
- ④ 100

30. 다중회귀분석에서 설명변수(독립변수)들 간에 강한 선형 상관관계가 존재하여 회귀계수 추정치의 분산이 커지고 통계적 유의성이 떨어지는 현상을 무엇이라 하는가?

- ① 이분산성 (Heteroscedasticity)
- ② 다중공선성 (Multicollinearity)
- ③ 과적합 (Overfitting)

④ 자기상관성 (Autocorrelation)

31. 회귀분석의 변수 선택 방법 중 "모든 독립변수가 포함된 전체 모형에서 출발하여, 모형에 대한 기여도가 가장 낮은 변수를 하나씩 순차적으로 제거해 나가는 방식"은?

- ① 전진 선택법 (Forward Selection)
- ② 후진 제거법 (Backward Elimination)
- ③ 단계별 선택법 (Stepwise Selection)
- ④ 완전 탐색법 (Exhaustive Search)

32. 다음 표는 로지스틱 회귀분석을 위한 어떤 이벤트의 확률(p)을 나타낸다. 확률 p가 0.8일 때, 이 사건이 발생할 오즈(Odds)의 값은 얼마인가?

지표	수치	공식
확률 (p)	0.8	
오즈 (Odds)	?	$p / (1-p)$

- ① 0.2
- ② 0.8
- ③ 4.0
- ④ 8.0

33. 시계열 데이터의 정상성(Stationarity)을 만족하기 위한 조건으로 옳바르지 않은 것은?

- ① 시간에 상관없이 평균이 일정한 상수이다.
- ② 시간에 상관없이 분산이 일정한 상수이다.
- ③ 두 시점 간의 공분산은 시간에 의존하지 않고 시차(Lag)에만 의존한다.
- ④ 시간에 따라 자기상관계수(ACF)가 지속적으로 증가하는 뚜렷한 추세를 가져야 한다.

34. 다음 중 비정상 시계열 데이터를 정상 시계열로 변환하는 방법에 대한 설명으로 옳바른 것은?

- ① 평균이 일정하지 않은 추세(Trend)를 가지는 경우, '로그 변환'을 적용한다.
- ② 분산이 시간에 따라 변동하는 이분산성을 가지는 경우, '차분(Differencing)'을 적용한다.
- ③ 평균의 비정상성은 '차분(Differencing)'을 통해 제거할 수 있다.
- ④ 정상성을 확보하기 위해 극단적인 이상치(Outlier)를 일괄 0으로 대체한다.

35. 의사결정나무(Decision Tree) 모델에 대한 설명으로 옳바르지 않은 것은?

- ① 결과를 해석하기 쉽고 이해하기 쉬운 화이트박스(White-box) 모델이다.
- ② 범주형 및 연속형 변수 모두 독립변수로 사용할 수 있다.
- ③ 나무가 깊어질수록 학습 데이터에 과적합(Overfitting)될 위험이 낮아진다.
- ④ 분류나무(Classification Tree)의 불순도 평가지표로 지니 지수, 엔트로피 지수 등이 사용된다.

36. 다음 표는 의사결정나무의 분할 전 특정 마디(Node)에 속한 데이터의 클래스 분포이다. 이 마디의 지니 지수(Gini Index)를 계산하시오.

클래스 범주	데이터 개수
성공 (Success)	40개
실패 (Failure)	60개
합계	100개

- ① 0.40
- ② 0.48
- ③ 0.50
- ④ 0.52

37. 인공신경망(ANN)의 은닉층에 사용되는 활성화 함수 중, 입력값이 0 미만일 때는 0을 출력하고, 0 이상일 때는 입력값을 그대로 출력하여 신경망의 '기울기 소실(Vanishing Gradient)' 문제를 크게 완화시킨 함수는?

- ① 시그모이드 함수 (Sigmoid)
- ② 렐루 함수 (ReLU)
- ③ 하이퍼볼릭 탄젠트 함수 (Tanh)
- ④ 소프트맥스 함수 (Softmax)

38. 인공신경망의 가중치 최적화 과정에서 출력층에서 발생한 오차(Error)를 역방향으로 전파하여 은닉층의 가중치를 미분(편미분) 연쇄 법칙을 통해 업데이트하는 알고리즘은 무엇인가?

- ① 전방향 전파 (Feed-forward)
- ② 역전파 알고리즘 (Backpropagation)
- ③ 경사 상승법 (Gradient Ascent)
- ④ 로짓 변환 알고리즘

39. 앙상블 학습(Ensemble Learning) 기법 중 "약한 학습기(Weak Learner)를 순차적으로 학습시키면서, 이전 모델이 잘못 예측한 오분류 데이터에 더 큰 가중치를 부여하여 다음 모델을

학습시키는 방식"은 무엇인가?

- ① 배깅 (Bagging)
- ② 랜덤 포레스트 (Random Forest)
- ③ 부스팅 (Boosting)
- ④ 스택킹 (Stacking)

40. 다음 표는 어떤 질병 진단 모델의 혼동행렬(Confusion Matrix)이다. 이 모델의 성능 평가 지표 중 특이도(Specificity)의 값은 얼마인가?

실제 / 예측	양성(Positive) 예측	음성(Negative) 예측
실제 양성(Positive)	90 (TP)	10 (FN)
실제 음성(Negative)	20 (FP)	80 (TN)

- ① 80/100 (0.80)
- ② 90/100 (0.90)
- ③ 90/110 (0.81)
- ④ 80/90 (0.88)

41. 분류 모델의 성능을 시각적으로 평가하는 ROC(Receiver Operating Characteristic) 곡선에 대한 설명으로 옳바르지 않은 것은?

- ① X축은 거짓 긍정률(FPR, 1-특이도)을 나타낸다.
- ② Y축은 진짜 긍정률(TPR, 민감도)을 나타낸다.
- ③ 곡선 아래의 면적을 나타내는 AUC 값이 1에 가까울수록 분류 성능이 우수함을 의미한다.
- ④ 모형의 성능이 무작위 추측(Random Guess)과 동일할 때 곡선은 좌상단 모서리로 완벽히 굽어지는 형태를 띈다.

42. 비지도 학습(Unsupervised Learning)에 해당하는 데이터 마이닝 기법을 모두 고른 것은? 가. 로지스틱 회귀분석 나. K-means 군집분석 다. 의사결정나무 라. 연관규칙분석(Apriori) 마. 인공신경망 다층 퍼셉트론

- ① 가, 다
- ② 나, 라
- ③ 다, 마
- ④ 가, 나, 마

43. K-means 군집분석 알고리즘에 대한 설명으로 가장 적절하지 않은 것은?

- ① 사용자가 초기에 군집의 수(k)를 직접 지정해야 한다.
- ② 데이터의 스케일에 매우 민감하므로 유클리드 거리를 계산하기 전 정규화/표준화 전처리가 권장된다.
- ③ 범주형 데이터(명목 변수)가 포함되어 있어도 별도의 변환 없이 곧바로 알고리즘 적용이 가능하다.
- ④ 군집 내 데이터들 간의 응집도를 높이기 위해 오차제곱합(SSE)이 최소화되는 중심점을 반복적으로 갱신한다.

44. 계층적 군집분석에서 두 군집 간의 거리를 측정하는 연결법 중 "두 군집이 하나로 병합되었을 때 생성되는 새로운 군집 내부의 오차제곱합(SSE)의 증가량이 가장 작아지는 군집끼리 묶어주는 방식"은?

- ① 단일 연결법 (Single Linkage)
- ② 완전 연결법 (Complete Linkage)
- ③ 평균 연결법 (Average Linkage)
- ④ 와드 연결법 (Ward's Method)

45. 차원 축소를 위한 주성분 분석(PCA) 결과, 각 주성분의 고윳값(Eigenvalue)이 아래 표와 같이 도출되었다. 카이저(Kaiser) 준칙에 따라 선택해야 할 가장 적절한 주성분의 개수는?

주성분 (PC)	고윳값 (Eigenvalue)
PC 1	3.5
PC 2	1.8
PC 3	1.1
PC 4	0.6
PC 5	0.2

- ① 1개
- ② 2개
- ③ 3개
- ④ 4개

46. 다차원척도법(MDS, Multidimensional Scaling)에 대한 설명으로 올바른 것은?

- ① 반응 변수(Y)가 명확히 주어질 때 판별 규칙을 찾는 지도학습이다.
- ② 객체들 간의 유사성(거리) 정보를 바탕으로 2차원 또는 3차원 공간 상의 점으로 시각화하는 기법이다.
- ③ 분석 모델의 예측 성능을 AUC 값으로 산출하여 보여주는 방법이다.

④ 시계열 데이터의 자기상관성(ACF)을 평가하기 위한 수치 지표이다.

47. 연관규칙분석(Association Rule)에서 다음 표의 데이터를 기반으로 규칙 X->Y의 향상도(Lift)를 올바르게 계산한 것은?

지표 항목	수치
전체 거래 건수	200건
품목 X가 포함된 거래 건수	100건
품목 Y가 포함된 거래 건수	60건
X와 Y 동시 포함 거래 건수	45건

- ① 0.75
- ② 1.00
- ③ 1.25
- ④ 1.50

48. 연관규칙 알고리즘 중 "최소 지지도(Minimum Support) 기준을 넘지 못하는 항목 집합의 모든 상위 확장 집합들은 검사 대상에서 제외(가지치기)하여 연산 속도를 획기적으로 향상시킨 알고리즘"은?

- ① DBSCAN
- ② Apriori 알고리즘
- ③ K-medoids 알고리즘
- ④ EM 알고리즘

49. 데이터 마이닝 수행 시 전체 데이터셋을 훈련용(Train), 검증용(Validation), 평가용(Test)으로 분할한다. 이때 '검증용(Validation)' 데이터의 주된 사용 목적은 무엇인가?

- ① 모델의 최종 배포 전, 학습에 전혀 관여하지 않은 상태에서 일반화 성능을 객관적으로 최종 평가하기 위해
- ② 모델이 학습하는 동안 하이퍼파라미터를 튜닝하고 과대적합(Overfitting)을 방지 및 조율하기 위해
- ③ 인공지능망의 가중치와 편향을 미분을 통해 직접적으로 학습하고 업데이트하기 위해
- ④ 원본 데이터의 결측치와 이상치를 삭제하거나 대체하기 위해

50. 다음 중 두 연속형 변수 간의 비선형(Non-linear)적인 관계나 서열 척도(순위) 데이터의 상관성을 평가할 때 사용하는 비모수적 상관계수는 무엇인가?

- ① 피어슨 상관계수 (Pearson)

- ② 유클리디안 거리 (Euclidean Distance)
 - ③ 자카드 계수 (Jaccard Coefficient)
 - ④ 스피어만 상관계수 (Spearman)
-

제2회 ADsP AI 모의고사

번호	정답	번호	정답	번호	정답	번호	정답	번호	정답
1	③	11	②	21	③	31	②	41	④
2	③	12	④	22	③	32	③	42	②
3	①	13	④	23	③	33	④	43	③
4	④	14	②	24	②	34	③	44	④
5	④	15	③	25	③	35	③	45	③
6	②	16	①	26	②	36	②	46	②
7	④	17	③	27	③	37	②	47	④
8	③	18	①	28	④	38	②	48	②
9	④	19	④	29	①	39	③	49	②
10	①	20	②	30	②	40	①	50	④

제2회 ADsP AI 모의고사

[제1과목: 데이터 이해]

1번 정답: ③ 지식(Knowledge)은 상호 연결된 정보 패턴을 이해하여 이를 토대로 근본적인 원리를 도출해 낸 것이다.

지식(Knowledge)은 정보의 패턴을 통해 예측 등 통찰을 도출한 것이며, 지혜(Wisdom)가 이를 바탕으로 한 근본적인 원리와 아이디어(어떻게 할 것인가)를 뜻합니다.

2번 정답: ③ ERP (Enterprise Resource Planning)

전사적 자원 관리 시스템은 ERP입니다. CRM은 고객 관계, SCM은 공급망 관리입니다.

3번 정답: ① (가) 가명처리, (나) 마스킹 및 범주화

홍길동을 다른 사람인 임꺽정으로 바꾸는 것은 가명처리, 홍** 및 30대로 뭉뚱그리는 것은 마스킹 및 범주화입니다.

4번 정답: ④ 분산 파일 시스템(Hadoop 등)을 구축하고 데이터 파이프라인을 설계하는 엔지니어링 능력

Hadoop 등 시스템 구축/엔지니어링 기술은 하드 스킬(Hard Skill)입니다.

5번 정답: ④ 데이터 간의 뚜렷한 인과관계(Causality) 규명을 최우선으로 삼는 방향으로 완전히 정착하였다.

빅데이터의 분석 방향은 원인을 증명하는 인과관계에서, 현상을 빠르게 엮어내는 상관관계 중심으로 이동했습니다.

6번 정답: ② 표출화 (Externalization)

내 머릿속의 지식(암묵지)을 밖으로 끄집어내어 문서(형식지)로 만드는 것은 표출화입니다.

7번 정답: ④ 모든 데이터가 철저히 정형화되어 있어, 분석 모델 간의 성능 차이가 발생하지 않기 때문이다.

데이터 분석 모델 간의 성능 차이가 나지 않는다는 것은 전혀 사실이 아니며 가치 산정의 어려움과도 무관합니다.

8번 정답: ③ 알고리즘리스트(Algorithmist) 직군 도입 및 알고리즘 접근권 허용

알고리즘 맹신으로 인한 부당한 피해(책임 원칙 훼손)를 막기 위해 알고리즘에 대한 해석 전문가(Algorithmist)와 알고리즘 접근권을 허용하는 방안이 대두됩니다.

9번 정답: ④ 비휘발성 데이터 (Non-volatile Data)

데이터베이스 4대 특징은 통합, 저장, 운영, 공유입니다. 비휘발성은 데이터 웨어하우스(DW)의 고유 특성입니다.

10번 정답: ① 테라(TB) -> 페타(PB) -> 제타(ZB) -> 엑사(EB)

데이터 단위 순서: KB -> MB -> GB -> TB -> PB -> EB -> ZB -> YB 입니다.

[제2과목: 데이터 분석 기획]

11번 정답: ② 솔루션(Solution): 분석 대상(What)은 알지만 분석 방법(How)을 모를 때 적용한다.

대상(What)은 알지만 방법(How)을 모를 때는 솔루션(Solution)입니다.

12번 정답: ④ 데이터 인프라(Data Infrastructure)

하향식 문제 탐색 5대 영역은 업무, 제품, 고객, 규제 및 거시 환경, 시장(경쟁자)입니다. 데이터 인프라는 포함되지 않습니다.

13번 정답: ④ 데이터 수집 및 시스템 구현 복잡도(난이도)

ROI 관점에서 투자비용(Investment) 요소는 데이터 수집/정제 및 시스템 적용의 난이도(비용)를 뜻합니다.

14번 정답: ② 데이터 이해 (Data Understanding)

데이터를 살피고 품질을 식별하며 EDA를 수행하는 초기 진단 단계는 CRISP-DM의 데이터 이해(Data Understanding)입니다.

15번 정답: ③ 정착형

인력/인프라(준비도)는 낮는데, 내부 통제 및 프로세스(성숙도)만 체계적인 사분면 유형은 정착형입니다.

16번 정답: ① 원칙(Principle), 조직(Organization), 프로세스(Process)

거버넌스 3대 기둥은 데이터 관리를 위한 원칙, 조직, 프로세스입니다.

17번 정답: ③ 최종적으로 적용될 딥러닝 모델의 은닉층 개수와 노드 수

분석 과제 정의서는 기획 단계의 개요 문서이므로, 향후 개발할 딥러닝 모델의 구체적인 하이퍼파라미터(은닉층 노드 수 등)를 미리 확정 기재할 수 없습니다.

18번 정답: ① 집중형 조직

현업에서 분석을 떼어내 별도의 중앙 전담 부서가 독점 제어하는 구조는 집중형 조직입니다.

19번 정답: ④ Data Ownership (데이터 소유권)

분석 프로젝트 관리를 위한 5대 속성은 데이터 크기(Size), 복잡도(Complexity), 속도(Speed), 분석 복잡도, 정확도와 정밀도입니다. 데이터 소유권은 해당되지 않습니다.

20번 정답: ② 상향식 접근법 (Bottom-up Approach)

가설 없이 데이터를 먼저 파헤치며 숨은 패턴을 찾아내는 귀납적 방식은 상향식 접근법(Bottom-up)입니다.

[제3과목: 데이터 분석]

21번 정답: ③ 등간척도 (Interval Scale)

덧셈/뺄셈은 되지만, 절대 영점이 없어 나눗셈(비율)은 안 되는 척도는 등간척도(온도 등)입니다.

22번 정답: ③ 평균 대체법(Mean Imputation)을 사용하면 표본 크기는 유지되지만, 해당 변수의 분산(Variance)이 과대 추정되는 문제가 발생한다.

평균 대체를 하면 데이터들이 평균값에 밀집하므로 분산은 커지는 것이 아니라 과소 추정됩니다.

23번 정답: ③ -20

$$IQR = Q3 - Q1 = 30 - 10 = 20$$

$$\text{Lower Fence} = Q1 - 1.5 \times IQR = 10 - 30 = -20$$

24번 정답: ② 귀무가설이 참일 때, 이를 잘못 기각하는 제1종 오류를 범할 확률의 최대 허용 한계

유의수준(α)은 귀무가설이 참인데도 이를 실수로 기각할(제1종 오류) 최대 허용 확률입니다.

25번 정답: ③ 층화추출: 모집단을 동질적인 여러 집단으로 나누고, 특정 하나의 집단만을 무작위로 선택하여 그 안에서 전수조사한다.

층화추출은 여러 층에서 모두 각각 골고루 임의 추출하는 방식입니다. 특정 층 하나만 골라 전수조사하는 것은 집락(군집)추출의 특징입니다.

26번 정답: ② 2/5

$P(\text{불만족} | \text{영업부}) = \text{영업부이면서 불만족인 사람} / \text{영업부 전체 인원} = 20 / 50 = 2/5$ 입니다.

27번 정답: ③ 데이터가 서열척도이거나 비선형적인 단조(Monotonic) 관계를 가질 때 적합한 비모수적 상관관계수이다.

스피어만 상관관계수는 서열(순위) 척도이거나 비선형 단조 관계를 측정하는 대표적인 비모수적 상관 분석 지표입니다.

28번 정답: ④ 다중공선성 (Multicollinearity)

선형회귀 잔차(오차)의 4대 기본 가정은 선형성, 독립성, 등분산성, 정규성입니다. 다중공선성은 독립변수 간의 문제입니다.

29번 정답: ① 10

$MSE = SSE / df(\text{잔차}) = 180 / 18 = 10$ 입니다.

30번 정답: ② 다중공선성 (Multicollinearity)

설명변수 간의 강한 상관성으로 추정이 망가지는 현상은 다중공선성입니다.

31번 정답: ② 후진 제거법 (Backward Elimination)

모두 넣은 상태에서 시작해 쓸모없는 변수부터 하나씩 지워나가는 방식은 후진 제거법입니다.

32번 정답: ③ 4.0

$Odds = p / (1-p) = 0.8 / 0.2 = 4.0$ 입니다.

33번 정답: ④ 시간에 따라 자기상관계수(ACF)가 지속적으로 증가하는 뚜렷한 추세를 가져야 한다.

정상 시계열은 자기상관계수(ACF)가 시간에 따라 증가하지 않고, 시차가 커짐에 따라 빠르게 0으로 소멸해야 합니다.

34번 정답: ③ 평균의 비정상성은 '차분(Differencing)'을 통해 제거할 수 있다.

평균의 비정상성(추세)은 차분으로 제거하고, 분산의 비정상성은 로그 변환으로 완화합니다.

35번 정답: ③ 나무가 깊어질수록 학습 데이터에 과적합(Overfitting)될 위험이 낮아진다.

의사결정나무는 깊이가 깊어질수록 가지가 잘게 쪼개지므로, 훈련 데이터에 너무 맞추어지는 과적합(Overfitting) 위험이 높아집니다.

36번 정답: ② 0.48

$Gini = 1 - (40/100)^2 - (60/100)^2 = 1 - 0.16 - 0.36 = 0.48$ 입니다.

37번 정답: ② 렐루 함수 (ReLU)

0 미만은 차단(0)하고, 0 이상은 그대로 내보내어 기울기 소실을 막은 함수는 렐루(ReLU)입니다.

38번 정답: ② 역전파 알고리즘 (Backpropagation)

출력 오차를 거꾸로 돌려보내며 은닉 가중치를 미분으로 수정하는 알고리즘은 역전파 알고리즘입니다.

39번 정답: ③ 부스팅 (Boosting)

틀린 데이터에 연속해서 가중치를 주어 다음 모형에 넘기는 순차적 앙상블은 부스팅입니다.

40번 정답: ① 80/100 (0.80)

특이도 = 실제 음성(100) 중 올바르게 음성으로 예측한 수(TN=80) = 80/100 (0.80)입니다.

41번 정답: ④ 모형의 성능이 무작위 추측(Random Guess)과 동일할 때 곡선은 좌상단 모서리로 완벽히 굽어지는 형태를 띈다.

모형의 성능이 무작위(동전 던지기)와 같으면 곡선은 좌상단이 아니라, 정중앙 대각선(직선) 형태를 띠게 됩니다. (AUC = 0.5)

42번 정답: ② 나, 라

정답 레이블이 없는 비지도 학습은 K-means 군집분석(나)과 연관규칙분석(라)입니다.

43번 정답: ③ 범주형 데이터(명목 변수)가 포함되어 있어도 별도의 변환 없이 곧바로 알고리즘 적용이 가능하다.

K-means는 평균 거리를 연산하는 거리 기반 모델이므로, 명목 변수(범주형 데이터)는 그대로 쓸 수 없고 원-핫 인코딩 등 전처리가 필요합니다.

44번 정답: ④ 와드 연결법 (Ward's Method)

병합 시 군집 내부의 오차제곱합(SSE) 증가량이 가장 적은 쌍을 고르는 안정적인 연결법은 와드 연결법입니다.

45번 정답: ③ 3개

카이저 준칙은 고유값 ≥ 1.0 인 주성분을 고르므로, PC1(3.5), PC2(1.8), PC3(1.1)로 총 3개입니다.

46번 정답: ② 객체들 간의 유사성(거리) 정보를 바탕으로 2차원 또는 3차원 공간 상의 점으로 시각화하는 기법이다.

객체 간 유사도 거리를 측정하여 이를 2차원/3차원 평면에 점으로 맵핑 시각화하는 기법은 다차원척도법(MDS)입니다.

47번 정답: ④ 1.50

$$\text{지지도}(X \cap Y) = 45/200 = 0.225$$

$$P(X) = 100/200 = 0.5, P(Y) = 60/200 = 0.3$$

$$\text{향상도} = 0.225 / (0.5 \times 0.3) = 0.225 / 0.15 = 1.50 \text{ 입니다.}$$

48번 정답: ② Apriori 알고리즘

최소 지지도를 넘지 못하면 그 상위 조합 검사를 과감히 포기(가지치기)하는 연관 알고리즘은 Apriori입니다.

49번 정답: ② 모델이 학습하는 동안 하이퍼파라미터를 튜닝하고 과대적합(Overfitting)을 방지 및 조율하기 위해

검증용(Validation) 데이터는 모델의 파라미터를 튜닝하고 과적합을 모니터링하여 여러 모델 중 최적 모델을 선정하기 위해 사용합니다.

50번 정답: ④ 스피어만 상관계수 (Spearman)

비선형 관계나 서열(순위) 기반의 상관 분석을 수행하는 비모수 계수는 스피어만 상관계수입니다.
