

[제1과목: 데이터 이해]

1. DIKW 피라미드 모델에 대한 설명으로 가장 적절한 것은?

- ① 데이터(Data): A마트의 휴지 가격은 1,000원이고, B마트의 휴지 가격은 1,200원이다.
- ② 정보(Information): A마트의 휴지가 B마트보다 싸기 때문에 A마트에서 휴지를 사야겠다.
- ③ 지식(Knowledge): A마트의 휴지 가격이 B마트보다 200원 더 저렴하다.
- ④ 지혜(Wisdom): 가공되지 않은 순수한 수치나 기호를 바탕으로 얻어지는 객관적 사실이다.

2. 데이터베이스의 일반적인 특징 중 "데이터베이스는 컴퓨터가 접근할 수 있는 조작 가능한 테이프, 디스크 등의 물리적 매체에 보관되어야 한다"는 속성은?

- ① 공용 데이터 (Shared Data)
- ② 통합 데이터 (Integrated Data)
- ③ 저장 데이터 (Stored Data)
- ④ 운영 데이터 (Operational Data)

3. "기업의 전반적인 경영 활동(인사, 재무, 생산, 물류 등)을 하나의 통합된 정보 시스템으로 구축하여 관리하는 시스템"은 무엇인가?

- ① CRM (Customer Relationship Management)
- ② SCM (Supply Chain Management)
- ③ ERP (Enterprise Resource Planning)
- ④ OLAP (Online Analytical Processing)

4. 빅데이터의 3V(Volume, Velocity, Variety) 특징 외에 추가로 거론되는 'V' 중에서, '빅데이터 분석을 통해 기업의 비즈니스 목적을 달성하고 실질적인 수익을 창출하는 궁극적인 결과물'을 뜻하는 것은?

- ① Veracity (정확성)
- ② Value (가치)
- ③ Visualization (시각화)
- ④ Variability (가변성)

5. 다음 중 개인정보 비식별화(De-identification) 처리 기법에 대한 설명으로 옳바르지 않은 것은?

- ① 가명처리: '홍길동'을 '회원A'와 같이 다른 식별자로 1:1 대체하는 기법이다.
 - ② 데이터 마스킹: 데이터의 일부분을 '*'나 공백 등으로 가려버리는 기법이다.
 - ③ 범주화: '35세'를 '30~40세'와 같이 포괄적인 값으로 변환하는 기법이다.
 - ④ 무작위화: 집단 데이터의 총합이나 평균값만을 남기고 개별 데이터를 완전히 삭제하는 기법이다.
-

6. 빅데이터 시대에 데이터 가치 산정이 특히 어려운 본질적인 이유로 가장 적절하지 않은 것은?

- ① 데이터가 본래 수집된 목적 외에도 다른 다양한 목적으로 재사용될 수 있기 때문이다.
 - ② 데이터가 기존에 없던 완전히 새로운 비즈니스 가치와 아이디어를 창출하기 때문이다.
 - ③ 데이터 분석 기술의 눈부신 발전으로 과거에는 분석 불가능했던 데이터가 새로운 가치를 갖게 되기 때문이다.
 - ④ 데이터 생산 비용이 기하급수적으로 증가하여, 기업들이 데이터 수집 자체를 포기하고 있기 때문이다.
-

7. 데이터 사이언티스트에게 요구되는 역량 중 '하드 스킬(Hard Skill)'에 해당하는 것은?

- ① 분석 결과를 기반으로 한 스토리텔링 및 프레젠테이션 역량
 - ② 최적화 알고리즘 구현 및 데이터베이스 처리 프로그래밍 기술
 - ③ 도메인 지식을 바탕으로 비즈니스 문제를 정의하는 통찰력
 - ④ 타 부서 인력들과 원활히 소통하고 협업하는 커뮤니케이션 능력
-

8. 지식경영의 핵심인 SECI 모델에서 "개인의 암묵지(Tacit Knowledge)가 대화, 모방, 현장 실습 등을 통해 다른 사람의 암묵지로 직접 전달되는 지식 공유 과정"은?

- ① 공통화 (Socialization)
 - ② 표출화 (Externalization)
 - ③ 연결화 (Combination)
 - ④ 내면화 (Internalization)
-

9. "과거에는 데이터에 기반하여 왜(Why) 그런 일이 발생했는지를 밝혀내는 데 주력했다면, 빅데이터 시대에는 무엇(What)이 일어날지를 빠르고 정확하게 찾아내는 데 집중한다"는 변화를 뜻하는 것은?

- ① 표본조사에서 전수조사로의 변화
 - ② 사후처리에서 사전처리로의 변화
 - ③ 데이터의 질(Quality) 중심에서 양(Quantity) 중심으로의 변화
 - ④ 인과관계(Causality) 중심에서 상관관계(Correlation) 중심으로의 변화
-

10. 빅데이터의 위기 요인인 '알고리즘의 오용이나 오류로 인한 부당한 피해(책임 원칙 훼손)'를 통제하기 위한 대안으로 가장 많이 거론되는 개념은?

- ① 사전 동의제 강화
- ② 익명화 기술의 전면 도입
- ③ 알고리즘리스트(Algorithmist) 직군 도입
- ④ 결과 기반 책임제 도입

[제2과목: 데이터 분석 기획]

11. "해결해야 할 분석 대상(What)과 분석 방법(How)을 모두 모를 때, 기존의 제약을 깨고 완전히 새로운 통찰을 통해 문제를 정의해 나가는 방식"은?

- ① 최적화 (Optimization)
- ② 솔루션 (Solution)
- ③ 통찰 (Insight)
- ④ 발견 (Discovery)

12. 하향식 접근법(Top-down Approach)의 '문제 탐색(Problem Discovery)' 단계에서 비즈니스 모델 캔버스를 활용할 때, 거시적 관점(Macro View)의 5대 탐색 영역에 속하지 않는 것은?

- ① 거시 환경 (STEEP)
- ② 경쟁자 (Competitor)
- ③ 고객 (Customer)
- ④ 분석 아키텍처 (Analytics Architecture)

13. 데이터 분석 마스터 플랜 수립 시 우선순위를 설정하는 기준에서, '시급성(Urgency)'과 가장 밀접하게 연관된 평가 지표는 무엇인가?

- ① 데이터 수집 및 가공의 복잡도
- ② 비즈니스 성과(Value) 및 전략적 중요도
- ③ 데이터 분석 시스템의 도입 비용
- ④ 전사 데이터 분석 인력의 역량 수준

14. 상향식 접근법(Bottom-up Approach)의 주요 특성으로 가장 거리가 먼 것은?

- ① 문제를 사전에 명확히 정의하기 어려운 비정형 환경에서 주로 사용된다.
- ② 데이터를 먼저 탐색하고 실험하는 과정(EDA)을 통해 문제와 인사이트를 도출한다.
- ③ 비지도 학습(Unsupervised Learning) 기법이 탐색 도구로 유용하게 쓰인다.

- ④ 논리적인 가설을 꼼꼼하게 먼저 수립한 뒤 이를 데이터로 증명하는 연역적 방식이다.
-

15. CRISP-DM 방법론의 프로세스 중, "데이터 마이닝 도구를 선택하고 최적의 알고리즘을 적용하여 파라미터를 튜닝하는 단계"는?

- ① 업무 이해 (Business Understanding)
 - ② 데이터 준비 (Data Preparation)
 - ③ 모델링 (Modeling)
 - ④ 평가 (Evaluation)
-

16. 데이터 거버넌스(Data Governance) 체계에서 '데이터 표준화(Data Standardization)' 활동에 포함되지 않는 것은 무엇인가?

- ① 표준 용어(Standard Dictionary) 설정
 - ② 명명 규칙(Naming Rule) 수립
 - ③ 메타데이터(Meta Data) 관리 체계 구축
 - ④ 분석 인력에 대한 교육 및 변화 관리 체계 수립
-

17. "데이터 분석 인프라와 인력 등 준비도(Readiness)는 매우 뛰어나지만, 전사 차원의 분석 프로세스 내재화(성숙도, Maturity)는 아직 낮은 기업"의 유형은?

- ① 도입형
 - ② 정착형
 - ③ 확산형
 - ④ 준비형
-

18. "별도의 독립된 전사 분석 전담 조직을 두지 않고 각 현업 부서 내에 분석 인력을 배치하여 해당 부서의 업무만 독자적으로 수행하는 구조"는 무엇인가?

- ① 집중형 조직
 - ② 기능 중심형 조직
 - ③ 분산형 조직
 - ④ 하이브리드 조직
-

19. 분석 프로젝트 관리를 위해 고려해야 할 5대 주요 속성(5 Key Attributes)에 대한 설명으로 옳바르지 않은 것은?

- ① Data Size: 처리해야 할 데이터의 물리적 크기를 의미한다.
- ② Speed: 분석 결과를 산출하고 현업에 적용하기까지 요구되는 시간이다.

- ③ Analytic Complexity: 분석 모델에 사용되는 알고리즘의 수학적 복잡도이다.
- ④ Security: 데이터 유출을 방지하기 위한 암호화 알고리즘의 수준이다.

20. '분석 과제 정의서'를 작성할 때 포함되어야 할 필수 항목으로 가장 적절하지 않은 것은?

- ① 분석 과제의 구체적인 배경 및 해결하고자 하는 질문
- ② 분석에 활용될 소스 데이터(Source Data) 내역
- ③ 최종 도입될 머신러닝 모형의 초기 랜덤 가중치(Weights) 값
- ④ 분석 결과를 현업에 적용했을 때 예상되는 정량적 기대 효과

[제3과목: 데이터 분석]

21. "분류나 범주를 나누기 위해 숫자를 부여하지만, 그 숫자들 사이에 크기나 순서의 의미가 전혀 없는 척도(예: 성별, 혈액형)"는 무엇인가?

- ① 명목척도 (Nominal Scale)
- ② 서열척도 (Ordinal Scale)
- ③ 등간척도 (Interval Scale)
- ④ 비율척도 (Ratio Scale)

22. 데이터 전처리 시 결측치(Missing Value) 처리에 대한 통계학적 설명으로 올바른 것은?

- ① 모든 결측치를 0으로 일괄 대체하면 데이터의 분산이 원래보다 과대 추정된다.
- ② 평균 대체법(Mean Imputation)을 사용하면 데이터의 흩어진 정도인 분산(Variance)이 과소 추정되는 경향이 있다.
- ③ 완전 제거법(Listwise Deletion)은 표본의 크기를 완벽히 보존하는 가장 훌륭한 방법이다.
- ④ 다중 대체법(Multiple Imputation)은 결측치를 무조건 최빈값으로 한 번만 채워 넣는 기법이다.

23. 다음 표는 어떤 연속형 변수에 대하여 상자그림(Boxplot)을 그리기 위해 산출한 사분위수(Quartiles) 정보이다. 이 데이터에서 극단적인 이상치(Outlier)를 판별하는 상한 임계치(Upper Fence)는 얼마인가?

통계 지표	수치값
제3사분위수 (Q3)	50
중앙값 (Q2)	35
제1사분위수 (Q1)	20

- ① 80
 - ② 85
 - ③ 90
 - ④ 95
-

24. "귀무가설(H_0)이 실제로 참(True)임에도 불구하고, 분석가의 실수나 표본의 우연성으로 인해 귀무가설을 기각하고 대립가설을 채택해 버리는 통계적 오류"는 무엇인가?

- ① 제1종 오류 (Type I Error)
 - ② 제2종 오류 (Type II Error)
 - ③ 계통 오차 (Systematic Error)
 - ④ 절단 오차 (Truncation Error)
-

25. 유의확률(p-value)에 대한 해석으로 가장 올바른 것은?

- ① p-value가 유의수준(α)보다 클 경우 귀무가설을 기각한다.
 - ② p-value는 대립가설이 참일 확률을 직접적으로 나타낸다.
 - ③ 귀무가설이 참이라는 가정하에, 표본 통계량이 관측된 값보다 더 극단적으로 나타날 확률이다.
 - ④ p-value가 0에 가까워질수록 귀무가설이 참일 가능성이 높다는 강력한 증거이다.
-

26. "모집단을 동질적인 여러 개의 층(Strata, 예: 성별, 연령대별)으로 분할한 뒤, 각 층마다 일정한 비율로 무작위 표본을 골고루 추출해내는 방식"은?

- ① 단순무작위추출법
 - ② 층화추출법 (Stratified Sampling)
 - ③ 계통추출법 (Systematic Sampling)
 - ④ 집락추출법 (Cluster Sampling)
-

27. 중심극한정리(Central Limit Theorem)에 대한 올바른 설명을 고르시오.

- ① 모집단의 원래 분포가 반드시 정규분포를 따라야만 성립한다.
 - ② 표본의 크기(n)가 클수록 모집단의 분포가 점차 정규분포로 변해간다.
 - ③ 모집단의 분포와 상관없이 표본 크기가 충분히 크면 '표본 평균'들의 분포는 정규분포에 근사한다.
 - ④ 표본의 분산이 중심극한정리에 의해 항상 0으로 수렴한다.
-

28. 스피어만(Spearman) 순위 상관계수에 대한 설명으로 옳바르지 않은 것은?

- ① 연속형 데이터뿐만 아니라 순위(서열) 척도 데이터에도 적용할 수 있다.
- ② 데이터 내에 극단적인 이상치(Outlier)가 포함되어 있을 때 피어슨 상관계수보다 덜 민감하다.

- ③ 두 변수 간의 비선형적인 단조(Monotonic) 증가/감소 관계도 파악할 수 있다.
- ④ 두 변수의 공분산을 각각의 표준편차의 곱으로 나눈 수식으로만 계산된다.

29. 단순선형회귀분석 적합 후 회귀모형의 통계적 유의성을 검정하기 위해 도출한 분산분석표(ANOVA)가 아래와 같다. 이 회귀모형의 F-통계량(F-statistic) 값은 얼마인가?

요인 (Source)	자유도 (df)	제곱합 (SS)
회귀 (Regression)	1	800
잔차 (Error)	18	180
총계 (Total)	19	980

- ① 10
- ② 44.4
- ③ 80
- ④ 100

30. 다중회귀분석에서 설명변수 간의 상관관계가 높아 추정된 회귀계수의 분산이 부풀려지는 현상인 '다중공선성(Multicollinearity)'을 진단하기 위해 확인하는 지표는?

- ① 결정계수 (R2)
- ② 더빈-왓슨 통계량 (Durbin-Watson)
- ③ 분산팽창요인 (VIF)
- ④ p-value

31. "초기 모형에 독립변수가 하나도 없는 상태에서 시작하여, 가장 설명력이 높은 변수부터 하나씩 차례로 모형에 추가해 나가는 방식"은?

- ① 전진 선택법 (Forward Selection)
- ② 후진 제거법 (Backward Elimination)
- ③ 단계별 선택법 (Stepwise Selection)
- ④ 릿지 회귀 (Ridge Regression)

32. 종속변수가 이진 범주형(성공/실패)일 때 사용하는 로지스틱 회귀분석(Logistic Regression)에서 사건이 발생할 확률(p)이 0.8일 때, '오즈(Odds)'의 크기는 얼마인가?

- ① 0.2
- ② 1.25
- ③ 4.0

33. 비정상 시계열 데이터를 분석 가능한 정상 시계열로 변환하려 한다. 시간이 흐름에 따라 분산(변동폭)이 기하급수적으로 커지는 현상을 안정시키기 위해 적용하는 가장 적절한 통계 변환은?

- ① 로그 변환 (Log Transformation)
- ② 차분 (Differencing)
- ③ 지수 평활 (Exponential Smoothing)
- ④ 더미 변수화

34. "과거 특정 시점들의 오차(백색잡음)들의 선형 결합으로 현 시점의 값을 예측하는 모형"은 무엇인가?

- ① 자기회귀 모형 (AR 모형)
- ② 이동평균 모형 (MA 모형)
- ③ 랜덤 워크 모형
- ④ 나이브 모형 (Naive Model)

35. 분류를 목적으로 하는 의사결정나무 모델에서 자식 마디를 분할할 때 불순도를 감소시키기 위해 사용하는 평가지표가 아닌 것은?

- ① 엔트로피 지수 (Entropy Index)
- ② 지니 지수 (Gini Index)
- ③ 카이제곱 통계량 (Chi-square)
- ④ 잔차제곱합 (SSE)

36. 의사결정나무 형성 시, 특정 마디(Node) 내부의 데이터 클래스 분포가 아래 표와 같다. 이 마디의 지니 지수(Gini Index) 값을 계산하시오.

범주 (Class)	관측 개수
A 클래스	20개
B 클래스	80개
합계	100개

- ① 0.16
- ② 0.32
- ③ 0.48
- ④ 0.64

37. "입력값이 0 미만이면 0을, 0 이상이면 입력값 그대로를 반환하여 기울기 소실(Vanishing Gradient) 문제를 혁신적으로 극복한 활성화 함수"는?

- ① 시그모이드 함수 (Sigmoid)
- ② 소프트맥스 함수 (Softmax)
- ③ 렐루 함수 (ReLU)
- ④ 하이퍼볼릭 탄젠트 함수 (Tanh)

38. 앙상블 학습 기법 중 하나인 '랜덤 포레스트(Random Forest)'의 핵심 원리에 대한 설명으로 옳바르지 않은 것은?

- ① 배깅(Bagging) 기법을 기반으로 다수의 의사결정나무를 결합한다.
- ② 각 나무를 학습할 때 전체 데이터에서 복원 추출(Bootstrap)을 수행한다.
- ③ 각 노드를 분할할 때 모든 변수를 검토하지 않고, 무작위로 추출된 일부 변수 부분집합만을 대상으로 최적의 분할을 찾는다.
- ④ 이전 나무 모델이 잘못 예측한 오분류 데이터에 가중치를 높게 부여하여 순차적으로 다음 나무를 학습시킨다.

39. 다음 표는 어떤 분류 예측 모델의 혼동행렬(Confusion Matrix)이다. 이 모델의 정확도(Accuracy)는 얼마인가?

실제 / 예측	참(True) 예측	거짓(False) 예측
실제 참(True)	60 (TP)	40 (FN)
실제 거짓(False)	20 (FP)	80 (TN)

- ① 0.60
- ② 0.65
- ③ 0.70
- ④ 0.80

40. 이진 분류 모델의 성능을 평가하는 ROC(Receiver Operating Characteristic) 곡선에서, 분류 성능이 완벽하게 훌륭한 이상적인 모델일 경우 AUC(Area Under Curve)의 값은 얼마인가?

- ① 0.0
- ② 0.5
- ③ 1.0
- ④ 100

41. 군집분석 알고리즘 중 'K-means (K-평균) 군집화'에 대한 설명으로 올바른 것은?

- ① 사전에 분석가가 설정해야 하는 하이퍼파라미터가 전혀 없다.
- ② 초기 중심점(Centroid)의 임의 배정 위치에 상관없이 항상 동일한 글로벌 최적해(Global Optimum)에 수렴한다.
- ③ 데이터의 스케일에 민감하므로 유클리드 거리를 사용하기 전 변수들의 정규화/표준화 전처리가 권장된다.
- ④ 달 모양이나 도넛 모양처럼 기하학적으로 복잡하게 얹힌 비선형 군집을 구분하는 데 매우 탁월하다.

42. 계층적 군집분석 수행 시 두 군집 간의 거리를 측정하는 연결법 중 "두 군집에 속한 모든 개체 조합 쌍의 거리를 구한 후, 그중 가장 먼 거리(최대값)를 두 군집 간의 거리로 정의하는 보수적인 방식"은?

- ① 단일 연결법 (Single Linkage)
- ② 완전 연결법 (Complete Linkage)
- ③ 평균 연결법 (Average Linkage)
- ④ 와드 연결법 (Ward's Method)

43. 데이터 마이닝 기법 중, 사전에 목표 변수(Y, 정답)가 존재하지 않는 비지도 학습(Unsupervised Learning)에 해당하지 않는 것은?

- ① 주성분 분석 (PCA)
- ② K-means 군집분석
- ③ 서포트 벡터 머신 (SVM)
- ④ 연관규칙분석 (Apriori)

44. 차원 축소를 위한 주성분 분석(PCA) 결과, 각 주성분(Principal Component)이 원본 데이터의 분산을 설명하는 누적 기여율 정보가 아래 표와 같다. 분석가가 원래 데이터 분산의 80% 이상을 보존하고자 할 때, 선택해야 할 가장 적은 수의 주성분 개수는 몇 개인가?

주성분 (PC)	고윳값 (Eigenvalue)	누적 기여율 (Cumulative %)
PC 1	2.5	45%
PC 2	1.5	72%
PC 3	0.8	86%
PC 4	0.4	93%
PC 5	0.2	100%

- ① 1개
- ② 2개
- ③ 3개
- ④ 4개

45. 장바구니 연관규칙 분석 결과가 아래 표와 같다. 규칙 A->B의 신뢰도(Confidence)와 향상도(Lift)를 순서대로 올바르게 짝지은 것은?

항목	거래 건수 및 확률
전체 거래 건수 (N)	100건
품목 A 단독 구매 확률 P(A)	0.5
품목 B 단독 구매 확률 P(B)	0.4
A와 B 동시 구매 확률 P(A∩B)	0.25

- ① 신뢰도: 0.50 / 향상도: 1.25
- ② 신뢰도: 0.25 / 향상도: 1.00
- ③ 신뢰도: 0.50 / 향상도: 0.625
- ④ 신뢰도: 0.625 / 향상도: 1.25

46. "최소 지지도(Minimum Support)의 임계치를 정해놓고 이를 넘지 못하는 품목 조합은 뺀어나가지 않고 가지치기(Pruning)하여 연산 속도를 기하급수적으로 줄인 고전적 알고리즘"은?

- ① K-NN
- ② SOM
- ③ DBSCAN
- ④ Apriori 알고리즘

47. 다차원척도법(MDS, Multidimensional Scaling) 분석의 주된 목적과 용도로 가장 적합한 것은?

- ① 독립변수들의 1차 선형 결합으로 종속변수의 수치값을 정확히 예측하는 것
- ② 변수 간의 분산을 극대화하는 새로운 직교 축을 찾아 다중공선성을 제거하는 것
- ③ 객체 간의 거리(유사성/비유사성) 정보를 바탕으로 2차원이나 3차원 평면상에 점으로 맵핑하여 직관적으로 시각화하는 것
- ④ 연쇄 편미분 법칙을 이용해 딥러닝 모형의 가중치를 업데이트하는 것

48. 데이터 분석을 수행할 때 전체 데이터를 훈련용(Train), 검증용(Validation), 평가용(Test)으로 3분할하는 목적과 역할에 대한 설명 중 '검증용 데이터'의 주된 역할은 무엇인가?

- ① 모델 내의 변수 가중치 매개변수를 반복 학습하여 패턴을 익히는 데 사용한다.
 - ② 여러 후보 모델을 비교하고 하이퍼파라미터를 튜닝하며 과대적합을 방지하기 위한 중간 평가에 사용한다.
 - ③ 학습이 완전히 종료된 후 최종 모델의 미래 예측 성능을 단 한 번 객관적으로 평가하는 데 사용한다.
 - ④ 분석에 앞서 결측치와 이상치를 시각적으로 파악하기 위한 EDA 전용 데이터이다.
-

49. K-means 군집 분석에서 최적의 군집 개수 k를 결정하기 위해, k가 증가함에 따라 집단 내 오차제곱합(SSE)이 감소하는 폭이 급격히 줄어들어 완만해지는 지점을 시각적으로 찾는 방법의 명칭은?

- ① 엘보우 기법 (Elbow Method)
 - ② 실루엣 분석 (Silhouette Analysis)
 - ③ 그리드 서치 (Grid Search)
 - ④ 라쏘 규제법 (Lasso)
-

50. 군집분석의 타당성을 평가하는 지표 중, "군집 내의 개체들은 얼마나 조밀하게 뭉쳐 있는지(응집도)와 다른 군집의 개체들과는 얼마나 멀리 떨어져 있는지(분리도)를 동시에 측정하여 -1에서 1 사이의 값으로 표현하는 지수"는 무엇인가?

- ① 엔트로피 지수
 - ② 스트레스 값 (Stress)
 - ③ 실루엣 계수 (Silhouette Coefficient)
 - ④ 다중공선성 지표 (VIF)
-

제4회 ADsP AI 모의고사

번호	정답	번호	정답	번호	정답	번호	정답	번호	정답
1	①	11	④	21	①	31	①	41	③
2	③	12	④	22	②	32	③	42	②
3	③	13	②	23	④	33	①	43	③
4	②	14	④	24	①	34	②	44	③
5	④	15	③	25	③	35	④	45	①
6	④	16	④	26	②	36	②	46	④
7	②	17	④	27	③	37	③	47	③
8	①	18	②	28	④	38	④	48	②
9	④	19	④	29	③	39	③	49	①
10	③	20	③	30	③	40	③	50	③

제4회 ADsP AI 모의고사

[제1과목: 데이터 이해]

1번 정답: ① 데이터(Data): A마트의 휴지 가격은 1,000원이고, B마트의 휴지 가격은 1,200원이다.

"A마트는 1,000원, B마트는 1,200원"이라는 순수 사실 자체는 가공되지 않은 데이터(Data)입니다. 이를 비교하여 "A가 더 싸다"는 것은 정보(Information)입니다.

2번 정답: ③ 저장 데이터 (Stored Data)

DB의 데이터는 디스크 등 컴퓨터가 접근 가능한 매체에 저장되어야 하므로 저장 데이터(Stored Data) 특성을 갖습니다.

3번 정답: ③ ERP (Enterprise Resource Planning)

전사적 자원 관리(인사, 재무, 생산 등 통합) 시스템은 ERP(Enterprise Resource Planning)입니다.

4번 정답: ② Value (가치)

빅데이터의 3V(Volume, Velocity, Variety)에 더하여 분석을 통한 경제적 결과물인 Value(가치)나 데이터의 신뢰성인 Veracity가 추가로 거론됩니다.

5번 정답: ④ 무작위화: 집단 데이터의 총합이나 평균값만을 남기고 개별 데이터를 완전히 삭제하는 기법이다.

집단 데이터의 총합이나 평균만 남기는 기법은 무작위화가 아니라 총계처리(Aggregation)입니다.

6번 정답: ④ 데이터 생산 비용이 기하급수적으로 증가하여, 기업들이 데이터 수집 자체를 포기하고 있기 때문이다.

데이터 생산 비용의 기하급수적 증가는 사실이 아니며, 센서 등의 발달로 수집 비용은 오히려 하락했습니다.

7번 정답: ② 최적화 알고리즘 구현 및 데이터베이스 처리 프로그래밍 기술

프로그래밍 기술, 수학적 알고리즘 구현 등은 데이터 사이언티스트의 전문 기술인 하드 스킬(Hard Skill)입니다.

8번 정답: ① 공통화 (Socialization)

암묵지가 다른 사람의 암묵지로 언어적 매개 없이 직접 전수(현장 실습 등)되는 과정은
공통화(Socialization)입니다.

9번 정답: ④ 인과관계(Causality) 중심에서 상관관계(Correlation) 중심으로의 변화

빅데이터 시대에는 복잡한 원인(Why)을 찾는 인과관계보다는, 데이터 패턴을 통해 무엇(What)이
일어날지 예측하는 상관관계(Correlation) 중심으로 패러다임이 변했습니다.

10번 정답: ③ 알고리즘리스트(Algorithmist) 직군 도입

알고리즘의 오용으로 인한 피해(책임 원칙 훼손)를 방지하기 위해 알고리즘의 타당성을 검증하는 해석
전문가인 알고리즘리스트(Algorithmist)가 대안으로 제시됩니다.

[제2과목: 데이터 분석 기획]

11번 정답: ④ 발견 (Discovery)

문제 대상(What)도 모르고 방법(How)도 모를 때 완전히 새로운 지식을 도출하는 것은
발견(Discovery)입니다.

12번 정답: ④ 분석 아키텍처 (Analytics Architecture)

비즈니스 모델 캔버스 거시 관점 탐색 5대 영역은 거시 환경(STEEP), 경쟁자, 시장, 고객, 채널 등입니다.
분석 아키텍처는 시스템 구축 용어입니다.

13번 정답: ② 비즈니스 성과(Value) 및 전략적 중요도

마스터 플랜에서 시급성을 판단하는 가장 중요한 축은 전략적 중요도와 비즈니스 성과(Value)입니다.

14번 정답: ④ 논리적인 가설을 꼼꼼하게 먼저 수립한 뒤 이를 데이터로 증명하는 연역적 방식이다.

가설을 먼저 수립하고 데이터를 통해 연역적으로 증명하는 방식은 하향식(Top-down) 접근법입니다.

15번 정답: ③ 모델링 (Modeling)

최적의 알고리즘을 적용하고 파라미터를 튜닝하여 모델을 구축하는 CRISP-DM 단계는
모델링(Modeling)입니다.

16번 정답: ④ 분석 인력에 대한 교육 및 변화 관리 체계 수립

데이터 거버넌스의 데이터 표준화 활동은 표준 용어 설정, 명명 규칙, 메타데이터 관리, 데이터 사전 구축입니다. 분석 인력 교육은 조직/문화 관리 영역입니다.

17번 정답: ④ 준비형

분석 인력 및 인프라(준비도)는 훌륭하지만, 전사 차원의 프로세스 내재화(성숙도)가 미비한 기업은 준비형(Readiness)입니다.

18번 정답: ② 기능 중심형 조직

별도 전담 조직 없이 각 현업 부서 내에서 자기 부서 업무만 독자적으로 수행하는 구조는 기능 중심형 조직입니다.

19번 정답: ④ Security: 데이터 유출을 방지하기 위한 암호화 알고리즘의 수준이다.

프로젝트 5대 속성 중 Security(보안)는 포함되지 않습니다. 5대 속성은 Data Size, Data Complexity, Speed, Analytic Complexity, Accuracy & Precision입니다.

20번 정답: ③ 최종 도입될 머신러닝 모형의 초기 랜덤 가중치(Weights) 값

분석 과제 정의서는 기획 단계에서 작성하는 개요 문서이므로, 향후 개발할 머신러닝 모형의 초기 랜덤 가중치 수치를 적는 것은 물리적으로 불가능합니다.

[제3과목: 데이터 분석]

21번 정답: ① 명목척도 (Nominal Scale)

범주를 구분할 뿐 크기나 순서의 의미가 없는 척도(혈액형, 성별)는 명목척도(Nominal Scale)입니다.

22번 정답: ② 평균 대체법(Mean Imputation)을 사용하면 데이터의 흩어진 정도인 분산(Variance)이 과소 추정되는 경향이 있다.

평균 대체법을 사용하면 모든 결측치가 하나의 값(평균)으로 몰리게 되므로, 데이터가 흩어진 정도인 분산(Variance)은 과소 추정(Underestimation)됩니다.

23번 정답: ④ 95

$$IQR = Q3 - Q1 = 50 - 20 = 30$$

$$\text{Upper Fence} = Q3 + 1.5 \times IQR = 50 + 45 = 95 \text{ 입니다.}$$

24번 정답: ① 제1종 오류 (Type I Error)

귀무가설이 참인데 이를 잘못 기각하는(죄 없는 사람을 유죄로 판결하는) 오류는 제1종 오류입니다.

25번 정답: ③ 귀무가설이 참이라는 가정하에, 표본 통계량이 관측된 값보다 더 극단적으로 나타날 확률이다.

p-value의 정확한 통계적 정의는 "귀무가설이 참이라는 가정하에, 현재 관측된 검정통계량 이상으로 극단적인 값이 나올 확률"입니다.

26번 정답: ② 층화추출법 (Stratified Sampling)

동질적인 여러 층으로 나누고 각 층에서 골고루 일정 비율을 뽑는 방식은 층화추출법(Stratified Sampling)입니다.

27번 정답: ③ 모집단의 분포와 상관없이 표본 크기가 충분히 크면 '표본 평균'들의 분포는 정규분포에 근사한다.

모집단이 어떤 형태든 표본 크기($n \geq 30$)가 크면 표본 평균의 분포는 정규분포에 근사한다는 것이 중심극한정리입니다.

28번 정답: ④ 두 변수의 공분산을 각각의 표준편차의 곱으로 나눈 수식으로만 계산된다.

스피어만 상관계수는 값 자체가 아니라 데이터의 순위(Rank)를 사용하여 계산하므로 공분산을 쓴다는 ④번 설명은 피어슨 계수의 설명입니다.

29번 정답: ③ 80

$$MSR = 800 / 1 = 800$$

$$MSE = 180 / 18 = 10$$

$$F\text{-통계량} = MSR / MSE = 800 / 10 = 80 \text{ 입니다.}$$

30번 정답: ③ 분산팽창요인 (VIF)

다중공선성을 진단하는 핵심 수치 지표는 분산팽창요인(VIF)이며 보통 10 이상일 때 심각하다고 봅니다.

31번 정답: ① 전진 선택법 (Forward Selection)

비어있는 모형에서 유의한 변수를 하나씩 앞으로 나아가며 추가하는 방식은 전진 선택법(Forward Selection)입니다.

32번 정답: ③ 4.0

Odds = $p / (1-p)$. $p=0.8$ 이므로 $0.8 / 0.2 = 4.0$ 입니다.

33번 정답: ① 로그 변환 (Log Transformation)

시계열 분석에서 분산이 기하급수적으로 커지는 이분산성을 안정화시키는 변환은 로그 변환(Log Transformation)입니다.

34번 정답: ② 이동평균 모형 (MA 모형)

과거 백색잡음(오차)들의 선형 결합으로 현 시점 값을 예측하는 모형은 이동평균(MA) 모형입니다.

35번 정답: ④ 잔차제곱합 (SSE)

잔차제곱합(SSE)은 범주를 분류하는 분류나무가 아니라 연속형 수치를 예측하는 회귀나무(Regression Tree)의 분할 평가 지표입니다.

36번 정답: ② 0.32

$Gini = 1 - (20/100)^2 - (80/100)^2 = 1 - 0.04 - 0.64 = 1 - 0.68 = 0.32$ 입니다.

37번 정답: ③ 렐루 함수 (ReLU)

음수는 0으로, 양수는 선형 통과시켜 딥러닝의 기울기 소실 문제를 극복한 가장 대표적인 함수는 렐루(ReLU)입니다.

38번 정답: ④ 이전 나무 모델이 잘못 예측한 오분류 데이터에 가중치를 높게 부여하여 순차적으로 다음 나무를 학습시킨다.

오분류 데이터에 가중치를 부여하여 순차적으로 다음 나무를 학습하는 것은 랜덤 포레스트(배깅 계열)가 아니라 부스팅(Boosting) 계열의 특징입니다.

39번 정답: ③ 0.70

정확도(Accuracy) = $(TP + TN) / Total = (60 + 80) / 200 = 140 / 200 = 0.70$ 입니다.

40번 정답: ③ 1.0

ROC 곡선 아래의 면적인 AUC 값은 성능이 100% 완벽할 때 최대치인 1.0을 가집니다.

41번 정답: ③ 데이터의 스케일에 민감하므로 유클리드 거리를 사용하기 전 변수들의 정규화/표준화 전처리가 권장된다.

K-means 알고리즘은 평균 거리를 계산하므로 변수의 스케일에 크게 영향을 받습니다. 따라서 정규화/표준화 전처리가 필수적으로 권장됩니다.

42번 정답: ② 완전 연결법 (Complete Linkage)

모든 개체 간 거리 중 최댓값(가장 먼 거리)을 보수적으로 기준으로 삼는 연결법은 완전 연결법(Complete Linkage)입니다.

43번 정답: ③ 서포트 벡터 머신 (SVM)

주성분 분석(PCA), K-means, 연관분석은 비지도 학습입니다. 하지만 서포트 벡터 머신(SVM)은 정답(Y)이 주어지는 강력한 지도 학습(분류/회귀) 기법입니다.

44번 정답: ③ 3개

누적 기여율 표에서 80%를 처음 돌파하는 지점은 PC3(86%)입니다. 따라서 최소 3개의 주성분이 필요합니다.

45번 정답: ① 신뢰도: 0.50 / 향상도: 1.25

신뢰도(Confidence) = $P(A \cap B) / P(A) = 0.25 / 0.5 = 0.50$
향상도(Lift) = 신뢰도 / $P(B) = 0.50 / 0.4 = 1.25$

46번 정답: ④ Apriori 알고리즘

최소 지지도를 넘지 못하는 품목 조합의 하위 가치를 과감히 쳐내(Pruning) 연산량을 줄인 알고리즘은 Apriori 알고리즘입니다.

47번 정답: ③ 객체 간의 거리(유사성/비유사성) 정보를 바탕으로 2차원이나 3차원 평면상에 점으로 맵핑하여 직관적으로 시각화하는 것

객체 간 거리나 유사성 정보를 2차원/3차원 공간상의 점으로 맵핑하여 직관적으로 시각화하는 기법은 다차원척도법(MDS)입니다.

48번 정답: ② 여러 후보 모델을 비교하고 하이퍼파라미터를 튜닝하며 과대적합을 방지하기 위한 중간 평가에 사용한다.

검증용(Validation) 데이터는 모델 가중치를 직접 학습시키진 않지만, 학습 도중 하이퍼파라미터 튜닝과 과적합 방지를 위해 모니터링(중간 평가)하는 용도로 쓰입니다.

49번 정답: ① 엘보우 기법 (Elbow Method)

군집 수 k 증가 시 SSE 감소폭이 확 꺾이는 팔꿈치 모양의 지점을 찾는 시각적 검증법은 엘보우 기법(Elbow Method)입니다.

50번 정답: ③ 실루엣 계수 (Silhouette Coefficient)

군집의 응집도와 분리도를 동시에 계량화하여 $-1 \sim 1$ 사이의 값으로 자율 군집을 평가하는 지수는 실루엣 계수(Silhouette Coefficient)입니다.
