

[제1과목: 데이터 이해]

1. DIKW 피라미드 구조에서 아래 예시가 해당하는 단계로 가장 알맞게 짝지어진 것은? (가) A편의점의 우유는 2,500원이고, B마트의 우유는 2,000원이다. (나) B마트의 우유가 A편의점보다 500원 더 저렴하다. (다) 우유를 대량으로 구매할 때는 B마트에서 사는 것이 예산을 절감하는 방법이다.

- ① (가) 데이터, (나) 정보, (다) 지식
- ② (가) 데이터, (나) 정보, (다) 지혜
- ③ (가) 정보, (나) 지식, (다) 지혜
- ④ (가) 정보, (나) 지식, (다) 데이터

2. 기업 내부 데이터베이스의 특징 중 "데이터베이스에 저장된 데이터는 단순한 보관용이 아니라, 조직의 고유한 업무와 기능을 수행하기 위해 반드시 존재해야 하는 핵심 데이터"임을 뜻하는 속성은?

- ① 공용 데이터 (Shared Data)
- ② 저장 데이터 (Stored Data)
- ③ 운영 데이터 (Operational Data)
- ④ 통합 데이터 (Integrated Data)

3. "기업의 다양한 원천 시스템(ERP, CRM 등)에서 발생한 데이터를 추출(Extract), 변환(Transform), 적재(Load)하여 다차원 분석과 의사결정 지원을 위해 구축된 전사적 규모의 데이터 저장소"는 무엇인가?

- ① OLTP (Online Transaction Processing)
- ② DW (Data Warehouse)
- ③ SCM (Supply Chain Management)
- ④ KMS (Knowledge Management System)

4. 빅데이터가 만들어내는 가치 패러다임의 진화 단계를 순서대로 올바르게 나열한 것은?

- ① Digitalization -> Connection -> Agency
- ② Connection -> Digitalization -> Agency
- ③ Digitalization -> Agency -> Connection
- ④ Agency -> Connection -> Digitalization

5. "알고리즘이 내린 예측 결과만을 맹신하여, 아직 범죄를 저지르지 않은 사람을 잠재적 범죄자로 예측해 불이익을 주는 등 민주주의의 기본 원칙을 훼손하는 현상"은?

- ① 사생활 침해
- ② 데이터 오용
- ③ 책임 원칙 훼손
- ④ 익명성 보장 실패

6. "구체적인 개인의 데이터를 성별: 남, 연령대: 30대, 거주지: 서울과 같이 포괄적인 값으로 변환하여 개인을 식별하지 못하게 하는 기법"은?

- ① 데이터 마스킹
- ② 범주화 (Categorization)
- ③ 총계처리 (Aggregation)
- ④ 가명처리 (Pseudonymization)

7. 지식경영의 핵심인 SECI 모델에 대한 설명으로 옳바르지 않은 것은?

- ① 공동화(Socialization): 암묵지가 다른 사람에게 암묵지로 전달되는 과정이다.
- ② 표출화(Externalization): 암묵지를 문서나 매뉴얼 등 형식지로 전환하는 과정이다.
- ③ 연결화(Combination): 여러 형식지들을 결합하여 새로운 형태의 암묵지를 창출하는 과정이다.
- ④ 내면화/Internalization): 형식지를 학습하여 개인의 새로운 암묵지로 체화하는 과정이다.

8. 데이터 사이언티스트에게 요구되는 역량 중 '소프트 스킬(Soft Skill)'에 해당하는 것만을 모두 고른 것은? 가. 통계학적 모델링 및 수학적 알고리즘 이해 나. 분석 결과를 명확하게 전달하는 시각화 및 스토리텔링 능력 다. 프로그래밍 언어(Python, R 등) 활용 능력 라. 도메인 지식을 바탕으로 비즈니스 문제를 정의하는 통찰력

- ① 가, 나
- ② 나, 다
- ③ 나, 라
- ④ 다, 라

9. 데이터 크기 단위의 크기 비교가 올바르게 된 것은?

- ① 페타바이트(PB) < 엑사바이트(EB) < 요타바이트(YB) < 제타바이트(ZB)
- ② 테라바이트(TB) < 페타바이트(PB) < 엑사바이트(EB) < 제타바이트(ZB)
- ③ 페타바이트(PB) < 엑사바이트(EB) < 테라바이트(TB) < 제타바이트(ZB)

④ 엑사바이트(EB) < 제타바이트(ZB) < 페타바이트(PB) < 요타바이트(YB)

10. 빅데이터의 가치 산정이 어려운 본질적인 이유를 설명한 것으로 가장 거리가 먼 것은?

- ① 특정 목적으로 수집된 데이터가 다른 다양한 목적으로 재사용될 수 있기 때문이다.
- ② 분석 기술의 비약적인 발전으로 기존에는 가치가 없던 데이터도 새로운 인사이트를 제공하기 때문이다.
- ③ 데이터가 기존에는 없던 완전히 새로운 비즈니스적 가치와 아이디어를 창출하기 때문이다.
- ④ 모든 데이터는 수집 즉시 경제적 가치가 숫자로 명확히 고정되기 때문이다.

[제2과목: 데이터 분석 기획]

11. "해결해야 할 분석 대상(What)은 명확하지 않지만, 구체적인 분석 방법(How)을 알고 있어 이를 통해 데이터를 파헤치며 새로운 의미를 도출하는 방식"은?

- ① 최적화 (Optimization)
- ② 솔루션 (Solution)
- ③ 통찰 (Insight)
- ④ 발견 (Discovery)

12. 하향식 접근법(Top-down Approach)의 분석 과제 도출 단계 중 '다양한 아이디어와 비즈니스 문제를 도출하기 위해 업무, 제품, 고객, 거시 환경 등을 거시적으로 살펴보는 단계'는?

- ① 문제 정의 (Problem Definition)
- ② 타당성 검토 (Feasibility Study)
- ③ 해결방안 탐색 (Solution Search)
- ④ 문제 탐색 (Problem Discovery)

13. 상향식 접근법(Bottom-up Approach)의 주요 특징에 대한 설명으로 가장 올바른 것은?

- ① 문제가 명확히 주어졌을 때 이를 논리적이고 연역적으로 해결하는 데 특화되어 있다.
- ② 인과관계(Causality) 규명을 최우선 분석 목표로 삼는다.
- ③ 비정형 환경에서 사전에 가설을 세우기 어려울 때, 데이터를 먼저 탐색(EDA)하며 통찰을 얻는다.
- ④ 비지도 학습 기법은 배제하고 오직 지도 학습 기법만을 사용한다.

14. CRISP-DM 방법론의 프로세스 중, "데이터 마이닝 도구를 선택하고 최적의 분석 알고리즘을 적용하여 모델을 구축하며, 파라미터 튜닝을 수행하는 단계"는 무엇인가?

- ① 업무 이해 (Business Understanding)
 - ② 데이터 준비 (Data Preparation)
 - ③ 모델링 (Modeling)
 - ④ 평가 (Evaluation)
-

15. 데이터 분석 마스터 플랜 수립 시 우선순위를 설정하는 기준인 '시급성'과 '난이도'에 대한 설명으로 옳바르지 않은 것은?

- ① 시급성은 전략적 중요도와 비즈니스 성과(Value)에 따라 결정된다.
 - ② 난이도는 데이터 획득의 용이성, 데이터 정제 비용, 시스템 적용 복잡도 등에 따라 결정된다.
 - ③ 포트폴리오 사분면 분석에서 가장 먼저 1순위로 추진해야 할 과제는 '시급성이 높고 난이도가 높은(어려운)' 과제이다.
 - ④ 투자 비용(Investment)은 난이도 축을 구성하는 주요 평가 요소이다.
-

16. 데이터 거버넌스(Data Governance) 체계에서 '데이터 품질 관리 체계'를 위한 활동에 가장 해당하지 않는 것은?

- ① 데이터의 정확성 및 오류를 주기적으로 점검하는 모니터링 체계 구축
 - ② 메타데이터 및 데이터 사전(Dictionary) 구축
 - ③ 데이터 품질 기준 수립 및 품질 지표(KPI) 정의
 - ④ 분석 모델의 최적 은닉층(Hidden Layer) 파라미터 자동 산출
-

17. "데이터 분석 인프라 및 기술 역량(준비도)은 매우 우수하나, 전사 차원의 분석 프로세스 내재화(성숙도) 수준이 아직 낮아 일부 부서에 국한된 기업 유형"은?

- ① 준비형
 - ② 도입형
 - ③ 정착형
 - ④ 확산형
-

18. "전사적으로 별도의 분석 전담 조직을 운영하지 않고, 마케팅, 재무, 생산 등 각 현업 부서 내에 분석 인력을 배치하여 독자적으로 분석을 수행하는 조직 유형"은?

- ① 집중형 조직
 - ② 분산형 조직
 - ③ 매트릭스형 조직
 - ④ 기능 중심형 조직
-

19. 다음 중 기획 단계에서 작성되는 '분석 과제 정의서'의 필수 포함 항목으로 가장 부적절한 것은?

- ① 프로젝트의 추진 배경 및 비즈니스 목적
- ② 분석에 필요한 원천 데이터(Source Data)의 종류와 획득 방안
- ③ 분석 결과를 실무에 적용했을 때 예상되는 정성적/정량적 기대 효과
- ④ 개별 분석가의 성과 평가 등급 및 급여 인상 기준

20. 데이터 마이닝의 프로젝트 5대 속성(5 Key Attributes)에 해당하지 않는 것은?

- ① Data Size (데이터 크기)
- ② Security (보안 수준)
- ③ Speed (분석 속도)
- ④ Accuracy & Precision (정확도와 정밀도)

[제3과목: 데이터 분석]

21. "분류나 순위뿐만 아니라 값들 사이의 간격이 의미를 가지며 덧셈과 뺄셈이 가능하지만, 절대적인 영점(0)이 없어 비율(나눗셈) 연산은 불가능한 척도(예: 섭씨온도)"는?

- ① 명목척도 (Nominal Scale)
- ② 서열척도 (Ordinal Scale)
- ③ 등간척도 (Interval Scale)
- ④ 비율척도 (Ratio Scale)

22. 데이터 전처리 시 결측치(Missing Value)의 '평균 대체법(Mean Imputation)'을 적용했을 때 나타나는 통계학적 특성으로 올바른 것은?

- ① 결측치를 평균으로 대체하면 원래 데이터의 분산(Variance)이 과대 추정된다.
- ② 표본의 크기(Sample Size)를 유지할 수 있지만, 데이터의 분산은 과소 추정(Underestimation)된다.
- ③ 데이터가 완전히 무작위로 결측되지 않았을 때 편향을 완벽하게 제거할 수 있다.
- ④ 단순 삭제법(Listwise Deletion)에 비해 데이터의 손실률이 기하급수적으로 증가한다.

23. 아래 표는 어떤 데이터셋의 사분위수(Quartiles) 통계량이다. 상자그림(Boxplot) 기준, 상한 임계치(Upper Fence)를 구하시오.

통계 지표	수치
제3사분위수 (Q3)	45

중앙값 (Q2)	30
제1사분위수 (Q1)	15

- ① 60
- ② 75
- ③ 90
- ④ 105

24. 통계적 가설검정에서 유의수준(Significance Level, α)의 올바른 정의는 무엇인가?

- ① 대립가설이 참일 때, 귀무가설을 올바르게 기각할 확률 (검정력)
- ② 귀무가설이 거짓일 때, 귀무가설을 기각하지 못하는 제2종 오류를 범할 확률
- ③ 귀무가설이 참일 때, 이를 잘못 기각하는 제1종 오류를 범할 확률의 최대 허용 한계
- ④ 표본 데이터가 정규분포를 따를 확률

25. 중심극한정리(Central Limit Theorem)에 대한 올바른 설명을 고르시오.

- ① 모집단의 원래 분포가 반드시 완벽한 대칭의 정규분포를 따라야만 성립한다.
- ② 표본의 크기(n)가 클수록 모집단의 분포가 점차 정규분포로 변해간다.
- ③ 표본 크기(n)가 충분히 크면, 모집단의 분포 모양과 관계없이 '표본 평균들의 분포'는 정규분포에 근사한다.
- ④ 시계열 데이터의 분산 비정상성을 해결하는 핵심 수학 정리이다.

26. "모집단을 서로 겹치지 않고 이질적인 구성원을 가진 여러 개의 집단(예: 학급, 마을)으로 나눈 뒤, 그중 일부 집단을 무작위로 선택하여 선택된 집단 내의 모든 개체를 전수조사하는 방식"은?

- ① 단순무작위추출법
- ② 층화추출법 (Stratified Sampling)
- ③ 계통추출법 (Systematic Sampling)
- ④ 집락추출법 (Cluster Sampling)

27. 피어슨(Pearson) 선형 상관계수 r 에 대한 설명으로 옳바르지 않은 것은?

- ① 두 변수의 공분산을 각각의 표준편차 곱으로 나누어 정규화하여 산출한다.
- ② 상관계수 r 이 0이면, 두 변수 사이에 어떠한 비선형(곡선) 관계도 절대 존재하지 않는다.
- ③ 절댓값이 1에 가까울수록 두 변수 간의 직선(선형) 관계가 강함을 의미한다.
- ④ 상관계수의 범위는 -1 이상 1 이하의 값을 가진다.

28. 선형회귀분석의 오차항(잔차)이 충족해야 하는 4대 기본 가정에 해당하지 않는 것은?

- ① 등분산성 (Homoscedasticity)
- ② 독립성 (Independence)
- ③ 다중공선성 (Multicollinearity)
- ④ 정규성 (Normality)

29. 다음은 단순선형회귀분석 적합 후 산출된 분산분석표(ANOVA)이다. 이 회귀모형의 설명력을 나타내는 결정계수(R^2) 값은 얼마인가?

요인 (Source)	제곱합 (SS)
회귀 (Regression, SSR)	600
잔차 (Error, SSE)	200
총계 (Total, SST)	800

- ① 0.25
- ② 0.33
- ③ 0.60
- ④ 0.75

30. 다중회귀분석에서 독립변수들끼리 강한 상관관계를 가져 회귀계수 추정이 불안정해지는 현상을 진단하기 위해 계산하는 지표로, 일반적으로 값이 10을 초과하면 심각하다고 판단하는 이 지표는?

- ① 수정된 결정계수 (Adjusted R^2)
- ② 더빈-왓슨 통계량 (Durbin-Watson)
- ③ 분산팽창요인 (VIF)
- ④ 피어슨 상관계수 (r)

31. "모든 독립변수가 포함된 상태에서 출발하여, 모형 설명에 기여도가 가장 낮은 변수를 하나씩 순차적으로 제거해 나가는 알고리즘"은?

- ① 전진 선택법 (Forward Selection)
- ② 후진 제거법 (Backward Elimination)
- ③ 단계별 선택법 (Stepwise Selection)
- ④ 완전 탐색법 (Exhaustive Search)

32. 종속변수가 범주형(성공/실패)일 때 사용하는 로지스틱 회귀분석에서, 어떤 사건이 발생할 확률(p)이 0.75일 때 '오즈(Odds)'의 크기는 얼마인가?

- ① 0.25
- ② 1.33
- ③ 3.0
- ④ 4.0

33. 비정상 시계열 데이터를 분석 가능한 정상 시계열로 변환하려 한다. 시간이 흐름에 따라 '평균'이 일정하지 않고 계속해서 상승하거나 하락하는 추세(Trend)를 지우기 위해 적용하는 가장 대표적인 전처리 변환은?

- ① 로그 변환 (Log Transformation)
- ② 차분 (Differencing)
- ③ 이동평균 스무딩
- ④ 정규화 (Normalization)

34. "과거 자기 자신의 관측값들을 독립변수로 삼아 현재 시점의 값을 예측하는 모형"은 무엇인가?

- ① 이동평균 모형 (MA 모형)
- ② 자기회귀 모형 (AR 모형)
- ③ 랜덤 워크 모형
- ④ 백색잡음 모형

35. 분류 분석을 위한 의사결정나무 모델에서, 마디(Node)를 분할할 때 순수도(Purity)를 평가하는 지표로 적합하지 않은 것은?

- ① 지니 지수 (Gini Index)
- ② 엔트로피 지수 (Entropy Index)
- ③ 카이제곱 통계량 (p-value)
- ④ 잔차제곱합 (SSE)

36. 의사결정나무 형성 과정에서 특정 마디(Node) 내부의 데이터 클래스 분포가 아래 표와 같다. 이 마디의 지니 지수(Gini Index) 값을 계산하시오.

범주 (Class)	데이터 개수
양성 (Positive)	40개
음성 (Negative)	60개
합계	100개

- ① 0.16

- ② 0.36
- ③ 0.48
- ④ 0.52

37. "입력값이 0 미만이면 0을 출력하고, 0 이상이면 입력값을 그대로 출력하여 기울기 소실(Vanishing Gradient) 문제를 혁신적으로 해결한 함수"는?

- ① 소프트맥스 함수 (Softmax)
- ② 하이퍼볼릭 탄젠트 함수 (Tanh)
- ③ 렐루 함수 (ReLU)
- ④ 시그모이드 함수 (Sigmoid)

38. 인공지능망 학습 과정에서, 출력층에서 도출된 오차를 앞쪽 은닉층으로 거꾸로 전파시키며 연쇄 미분 법칙을 통해 가중치(Weight)를 업데이트하는 딥러닝의 핵심 최적화 알고리즘은?

- ① 전방향 전파 (Feed-forward)
- ② 역전파 알고리즘 (Backpropagation)
- ③ 차원 축소법
- ④ 경사 상승법

39. 앙상블 학습 기법 중 하나인 '랜덤 포레스트(Random Forest)'의 특징으로 옳바르지 않은 것은?

- ① 여러 개의 의사결정나무를 독립적으로 학습시켜 결과를 결합하는 배깅(Bagging) 기법의 일종이다.
- ② 학습 시 데이터셋에서 복원 추출을 허용하는 부트스트래핑(Bootstrapping)을 수행한다.
- ③ 각 노드를 분할할 때 모든 독립변수를 검토하여 가장 불순도를 낮추는 최적의 변수를 무조건 선택한다.
- ④ 변수의 무작위 추출(Random Feature Selection)을 통해 개별 나무 모형들 간의 상관관계를 낮춘다.

40. 다음 표는 어떤 이진 분류 모델의 혼동행렬(Confusion Matrix)이다. 이 모델의 재현율(Recall, 민감도) 값은 얼마인가?

실제 / 예측	참(True) 예측	거짓(False) 예측
실제 참(True)	90 (TP)	10 (FN)
실제 거짓(False)	20 (FP)	80 (TN)

- ① 0.80
- ② 0.81

- ③ 0.90
- ④ 0.95

41. 분류 모델의 성능을 평가하는 ROC 곡선(ROC Curve)에 대한 설명으로 옳바르지 않은 것은?

- ① 가로축(X축)은 거짓 긍정률(FPR, 1-특이도)을 나타낸다.
- ② 세로축(Y축)은 진짜 긍정률(TPR, 민감도, 재현율)을 나타낸다.
- ③ 곡선 아래 면적인 AUC(Area Under Curve) 값이 0.5에 가까울수록 성능이 매우 우수함을 뜻한다.
- ④ 분류 임계값이 변함에 따라 민감도와 1-특이도가 어떻게 변하는지 시각화한 그래프이다.

42. 다음 중 사전에 정답(Target Label, Y)이 주어지지 않은 상태에서 데이터 자체의 유사성만을 바탕으로 패턴을 찾는 '비지도 학습(Unsupervised Learning)' 기법이 아닌 것은?

- ① 로지스틱 회귀분석
- ② 주성분 분석 (PCA)
- ③ K-means 군집분석
- ④ 다차원척도법 (MDS)

43. 비지도 학습인 K-means 군집분석 알고리즘에 대한 설명으로 가장 적절하지 않은 것은?

- ① 초기 군집 중심점(Centroid)의 무작위 배정 위치에 따라 매번 최종 군집 결과가 달라질 수 있다.
- ② 유클리디안 거리를 연산하므로 데이터의 스케일에 민감하여 분석 전 정규화 전처리가 필요하다.
- ③ 분석가가 사전에 군집의 총 개수 k를 임의로 직접 지정해 주어야 한다.
- ④ 범주형(명목형) 변수가 포함되어 있어도 변환 없이 그대로 거리 연산이 완벽하게 가능하다.

44. "두 군집이 병합되었을 때 군집 내 오차제곱합(SSE)의 증가량이 가장 적어지는 방향으로 군집을 묶어나가는 안정적인 연결법"은?

- ① 단일 연결법 (Single Linkage)
- ② 평균 연결법 (Average Linkage)
- ③ 완전 연결법 (Complete Linkage)
- ④ 와드 연결법 (Ward's Method)

45. 차원 축소를 위해 주성분 분석(PCA)을 수행하여 아래 표와 같은 고윳값(Eigenvalue) 결과를 얻었다. 카이저(Kaiser) 준칙을 적용하여 추출할 때, 가장 적절한 주성분의 개수는?

주성분 (PC)	고윳값 (Eigenvalue)
PC 1	4.2

PC 2	2.1
PC 3	0.9
PC 4	0.5
PC 5	0.2

- ① 1개
- ② 2개
- ③ 3개
- ④ 4개

46. 다차원척도법(MDS, Multidimensional Scaling)의 분석 목적으로 가장 적절한 것은?

- ① 시간의 흐름에 따른 변수의 추세를 예측하기 위함이다.
- ② 객체들 간의 유사성(거리) 구조를 2차원 또는 3차원 공간상에 점으로 맵핑하여 직관적으로 시각화하기 위함이다.
- ③ 독립변수와 종속변수 간의 인과관계를 통계적으로 증명하기 위함이다.
- ④ 다중공선성을 진단하고 회귀계수의 분산을 측정하기 위함이다.

47. 장바구니 연관규칙분석에서 품목 간 거래 건수를 조사한 결과가 아래 표와 같다. 규칙 X->Y의 향상도(Lift) 값을 계산하시오.

항목	거래 건수
전체 거래 건수	1,000건
품목 X 구매 건수	200건
품목 Y 구매 건수	100건
품목 X와 Y 동시 구매 건수	50건

- ① 0.25
- ② 0.50
- ③ 2.00
- ④ 2.50

48. "최소 지지도(Minimum Support)의 기준치를 정하고, 이 기준을 넘지 못하는 품목 조합은 그 상위 확장을 모두 검사에서 제외(가지치기)하여 연산 속도를 획기적으로 올린 대표적 알고리즘"은?

- ① Apriori 알고리즘
- ② K-medoids 알고리즘

- ③ EM 알고리즘
 - ④ DBSCAN
-

49. 데이터 모델링 시 원본 데이터셋을 훈련용(Train), 검증용(Validation), 평가용(Test)으로 분할한다. 이때 '검증용 데이터'의 주요 역할은 무엇인가?

- ① 모델의 최종 일반화 예측 성능을 단 한 번 완벽히 객관적으로 평가하기 위해 숨겨두는 데이터이다.
 - ② 학습 도중 하이퍼파라미터를 튜닝하고, 과대적합(Overfitting)을 모니터링하여 최적의 모델을 선정하는 조율용 데이터이다.
 - ③ 딥러닝 네트워크 내부의 순수 가중치 매개변수들을 직접적으로 반복 학습시키는 메인 훈련 데이터이다.
 - ④ 데이터 분석 기획 초기 단계에서 EDA를 수행하기 위한 탐색 전용 데이터이다.
-

50. "모집단을 서로 겹치지 않는 동질적인 여러 개의 층(Strata, 예: 학년별, 직급별)으로 나눈 뒤, 각 층마다 일정한 비율로 무작위 표본을 모두 골고루 추출해내는 기법"은?

- ① 단순무작위추출법
 - ② 계통추출법 (Systematic Sampling)
 - ③ 집락추출법 (Cluster Sampling)
 - ④ 층화추출법 (Stratified Sampling)
-

제5회 ADsP AI 모의고사

번호	정답	번호	정답	번호	정답	번호	정답	번호	정답
1	①	11	③	21	③	31	②	41	③
2	③	12	④	22	②	32	③	42	①
3	②	13	③	23	③	33	②	43	④
4	①	14	③	24	③	34	②	44	④
5	③	15	③	25	③	35	④	45	②
6	②	16	④	26	④	36	③	46	②
7	③	17	①	27	②	37	③	47	④
8	③	18	④	28	③	38	②	48	①
9	②	19	④	29	④	39	③	49	②
10	④	20	②	30	③	40	③	50	④

[제1과목: 데이터 이해]

1번 정답: ① (가) 데이터, (나) 정보, (다) 지식

(가)는 사실인 데이터, (나)는 비교를 통한 의미 도출인 정보, (다)는 정보의 패턴을 통해 예측/해결책을 낸 지식입니다.

2번 정답: ③ 운영 데이터 (Operational Data)

고유 업무를 위해 필수적으로 존재하고 활용되어야 하는 성질은 데이터베이스의 운영 데이터(Operational Data) 속성입니다.

3번 정답: ② DW (Data Warehouse)

전사적 규모의 다차원 분석을 위해 다양한 원천 데이터를 모아둔 통합 저장소는 데이터 웨어하우스(DW)입니다.

4번 정답: ① Digitalization -> Connection -> Agency

빅데이터 가치 패러다임은 Digitalization(디지털화) -> Connection(연결) -> Agency(에이전시/자동화) 순으로 발전했습니다.

5번 정답: ③ 책임 원칙 훼손

행위를 하기도 전에 예측 결과만으로 불이익을 주어 민주주의를 위협하는 부작용을 책임 원칙 훼손이라 합니다.

6번 정답: ② 범주화 (Categorization)

35세를 30대로, 상세 주소를 서울시 등 포괄적인 구간으로 변환하여 식별성을 낮추는 기술은 범주화(Categorization)입니다.

7번 정답: ③ 연결화(Combination): 여러 형식지들을 결합하여 새로운 형태의 암묵지를 창출하는 과정이다.

여러 형식지를 결합하여 더 고도화된 형식지 시스템을 만드는 과정이 연결화(Combination)입니다. 암묵지를 창출하는 것이 아닙니다.

8번 정답: ③ 나, 라

통계/프로그래밍 등 수리적 기술은 하드 스킬이며, 시각화/스토리텔링/통찰력(나, 라)은 비즈니스 소양인 소프트 스킬입니다.

9번 정답: ② 테라바이트(TB) < 페타바이트(PB) < 엑사바이트(EB) < 제타바이트(ZB)

용량 단위 크기는 TB -> PB -> EB -> ZB -> YB 순으로 커집니다.

10번 정답: ④ 모든 데이터는 수집 즉시 경제적 가치가 숫자로 명확히 고정되기 때문이다.

데이터는 수집 즉시 고정된 경제적 가치가 매겨지는 것이 아니라, 누가 어떻게 쓰느냐(다목적 재사용성)에 따라 가치가 급변하기 때문에 산정이 어렵습니다.

[제2과목: 데이터 분석 기획]

11번 정답: ③ 통찰 (Insight)

대상(What)은 불명확하나 분석 방법(How)은 확실할 때 숨은 의미를 찾는 기획은 통찰(Insight)입니다.

12번 정답: ④ 문제 탐색 (Problem Discovery)

하향식 접근법의 첫 단계는 업무/제품/고객 등 거시 환경을 살펴 문제를 발굴하는 문제 탐색(Problem Discovery) 단계입니다.

13번 정답: ③ 비정형 환경에서 사전에 가설을 세우기 어려울 때, 데이터를 먼저 탐색(EDA)하며 통찰을 얻는다.

상향식은 비정형 환경 등 문제 정의가 어려울 때, 데이터를 먼저 탐색(EDA)하며 아이디어를 얻는 귀납적 방식입니다.

14번 정답: ③ 모델링 (Modeling)

알고리즘 적용 및 파라미터 튜닝을 통해 최적의 예측 모델을 수립하는 핵심 단계는 모델링(Modeling)입니다.

15번 정답: ③ 포트폴리오 사분면 분석에서 가장 먼저 1순위로 추진해야 할 과제는 '시급성이 높고 난이도가 높은(어려운)' 과제이다.

포트폴리오 사분면에서 가장 먼저 1순위로 추진해야 하는 최고의 과제는 시급성이 높고(즉시 수익), 난이도는 낮은(구현이 쉬운) 과제입니다.

16번 정답: ④ 분석 모델의 최적 은닉층(Hidden Layer) 파라미터 자동 산출

데이터 품질 관리 체계는 정합성 점검, 지표 수립 등을 뜻합니다. 분석 모델의 은닉층 파라미터 산출은 머신러닝 최적화 영역으로 품질 관리 체계가 아닙니다.

17번 정답: ① 준비형

분석 조직/인프라(준비도)는 매우 훌륭하나, 전사 표준화 및 내재화(성숙도)가 미비한 유형은 준비형(Readiness)입니다.

18번 정답: ④ 기능 중심형 조직

전담 조직 없이 개별 현업 부서 내에 자체적으로 분석 인력을 두어 독자 수행하는 구조는 기능 중심형 조직입니다.

19번 정답: ④ 개별 분석가의 성과 평가 등급 및 급여 인상 기준

분석 과제 정의서는 기획 시 작성하는 문서이므로, 개별 분석가의 인사 고과나 급여 인상 기준을 적는 것은 부적절합니다.

20번 정답: ② Security (보안 수준)

5대 속성은 Size, Complexity, Speed, Analytic Complexity, Accuracy & Precision입니다. Security(보안)는 아닙니다.

[제3과목: 데이터 분석]

21번 정답: ③ 등간척도 (Interval Scale)

덧셈/뺄셈 등 간격은 의미가 있으나 절대 영점이 없어 곱셈/나눗셈(비율) 연산이 불가능한 척도(온도 등)는 등간척도(Interval Scale)입니다.

22번 정답: ② 표본의 크기(Sample Size)를 유지할 수 있지만, 데이터의 분산은 과소 추정(Underestimation)된다.

평균으로 모두 채워 넣으면 값들이 중앙에 쏠리므로, 흩어진 정도인 분산(Variance)이 원래보다 과소 추정됩니다.

23번 정답: ③ 90

$$IQR = Q3(45) - Q1(15) = 30$$

$$\text{Upper Fence} = Q3 + 1.5 \times IQR = 45 + 45 = 90 \text{ 입니다.}$$

24번 정답: ③ 귀무가설이 참일 때, 이를 잘못 기각하는 제1종 오류를 범할 확률의 최대 허용 한계

유의수준(α)은 참인 귀무가설을 잘못 기각해버리는 제1종 오류의 최대 허용 한계입니다.

25번 정답: ③ 표본 크기(n)가 충분히 크면, 모집단의 분포 모양과 관계없이 '표본 평균들의 분포'는 정규분포에 근사한다.

중심극한정리는 원 데이터 모양과 무관하게 표본 크기가 충분히 크면 표본 평균들의 분포가 정규분포를 따른다는 기적의 통계 정리입니다.

26번 정답: ④ 집락추출법 (Cluster Sampling)

이질적인 여러 집단(학급 등)으로 나눈 뒤 일부 집단만 무작위로 통째로 골라 전수조사하는 방식은 집락추출법(Cluster Sampling)입니다.

27번 정답: ② 상관계수 r 이 0이면, 두 변수 사이에 어떠한 비선형(곡선) 관계도 절대 존재하지 않는다.

피어슨 $r = 0$ 은 직선(선형) 관계가 없다는 뜻일 뿐, 2차 함수 같은 곡선(비선형) 관계는 뚜렷하게 존재할 수 있습니다.

28번 정답: ③ 다중공선성 (Multicollinearity)

선형회귀 잔차의 4대 기본 가정은 선형성, 독립성, 등분산성, 정규성입니다. 다중공선성은 독립변수들끼리의 문제이지 잔차의 가정이 아닙니다.

29번 정답: ④ 0.75

$$R^2 = SSR / SST = 600 / 800 = 0.75 \text{ 입니다.}$$

30번 정답: ③ 분산팽창요인 (VIF)

독립변수 간의 상관관계로 회귀 추정이 망가지는 현상을 진단하는 대표 수치 지표는 분산팽창요인(VIF)입니다.

31번 정답: ② 후진 제거법 (Backward Elimination)

모두 넣은 꼭 찬 상태에서 출발해 필요 없는 변수를 하나씩 지우며 뒤로 가는 방식은 후진 제거법입니다.

32번 정답: ③ 3.0

$Odds = p / (1-p)$. $p=0.75$ 일 때 $Odds = 0.75 / 0.25 = 3.0$ 입니다.

33번 정답: ② 차분 (Differencing)

시계열 데이터의 추세(평균 비정상성)는 차분으로 지우지만, 분산이 커지는 비정상성은 값의 스케일을 줄여주는 로그 변환(Log)으로 안정화합니다.

34번 정답: ② 자기회귀 모형 (AR 모형)

과거 자기 자신의 관측값을 독립 변수로 삼아 스스로 회귀 예측하는 모형은 자기회귀(AR) 모형입니다.

35번 정답: ④ 잔차제곱합 (SSE)

잔차제곱합(SSE)은 범주형 분류가 아니라 연속형 수치를 예측하는 회귀나무(Regression Tree)의 분할 평가 지표입니다.

36번 정답: ③ 0.48

$Gini = 1 - (40/100)^2 - (60/100)^2 = 1 - 0.16 - 0.36 = 1 - 0.52 = 0.48$ 입니다.

37번 정답: ③ 렐루 함수 (ReLU)

0 미만은 0으로, 0 이상은 선형 통과시켜 딥러닝 층을 깊게 쌓을 수 있게 한 핵심 함수는 렐루(ReLU)입니다.

38번 정답: ② 역전파 알고리즘 (Backpropagation)

출력 오차를 뒤에서부터 역으로 전파하며 은닉 가중치를 미분 수정하는 알고리즘은 역전파 알고리즘(Backpropagation)입니다.

39번 정답: ③ 각 노드를 분할할 때 모든 독립변수를 검토하여 가장 불순도를 낮추는 최적의 변수를 무조건 선택한다.

랜덤 포레스트는 노드 분할 시 모든 독립변수를 검토하지 않고, 매번 무작위로 뽑힌 일부 변수들(Random Feature Subset) 내에서만 최적 분할을 찾습니다.

40번 정답: ③ 0.90

재현율(민감도) = $TP / (TP + FN) = 90 / (90 + 10) = 90 / 100 = 0.90$ 입니다.

41번 정답: ③ 곡선 아래 면적인 AUC(Area Under Curve) 값이 0.5에 가까울수록 성능이 매우 우수함을 뜻한다.

ROC 곡선 아래 면적인 AUC 값이 0.5면 완전 무작위(동전 던지기) 수준이며, 1.0에 가까울수록 분류 성능이 매우 우수함을 뜻합니다.

42번 정답: ① 로지스틱 회귀분석

로지스틱 회귀분석은 정답 타겟 레이블(성공/실패)이 명확히 주어져 있는 지도 학습(Supervised Learning) 모델입니다.

43번 정답: ④ 범주형(명목형) 변수가 포함되어 있어도 변환 없이 그대로 거리 연산이 완벽하게 가능하다.

K-means는 유클리드 거리 등 기하학적 거리 연산을 하므로 범주형(명목형) 변수는 그대로 쓸 수 없으며, 원-핫 인코딩 등 거리 변환 전처리가 필수적입니다.

44번 정답: ④ 와드 연결법 (Ward's Method)

군집 병합 시 발생하는 내부 오차제곱합(SSE) 증분 크기를 최소화하는 가장 안정적인 결합 방식은 와드 연결법(Ward's Method)입니다.

45번 정답: ② 2개

카이저(Kaiser) 준칙은 고유값이 1.0 이상인 주성분만 고릅니다. 표에서 PC1(4.2), PC2(2.1)이므로 총 2개입니다.

46번 정답: ② 객체들 간의 유사성(거리) 구조를 2차원 또는 3차원 공간상에 점으로 맵핑하여 직관적으로 시각화하기 위함이다.

복잡한 객체 간 유사도(거리)를 2차원/3차원 평면에 맵핑(점 찍기)하여 직관적으로 시각화하는 기술은 다차원척도법(MDS)입니다.

47번 정답: ④ 2.50

$$P(X \cap Y) = 50/1000 = 0.05$$

$$P(X) = 200/1000 = 0.2, P(Y) = 100/1000 = 0.1$$

$$\text{향상도(Lift)} = 0.05 / (0.2 \times 0.1) = 0.05 / 0.02 = 2.50 \text{ 입니다.}$$

48번 정답: ① Apriori 알고리즘

최소 지지도를 넘지 못하면 그 상위 조합은 보지도 않고 쳐내어(Pruning) 연산량을 기하급수적으로 줄인 대표 알고리즘은 Apriori 알고리즘입니다.

49번 정답: ② 학습 도중 하이퍼파라미터를 튜닝하고, 과대적합(Overfitting)을 모니터링하여 최적의 모델을 선정하는 조율용 데이터이다.

검증용(Validation) 데이터는 직접 학습에 쓰이지 않지만, 학습 도중 하이퍼파라미터 튜닝과 과대적합 방지를 위해 모니터링 조율하는 목적의 세트입니다.

50번 정답: ④ 층화추출법 (Stratified Sampling)

모집단을 동질적인 여러 층(학년 등)으로 분할하고, 모든 층에서 각각 일정 비율을 무작위 추출하여 대표성을 보장하는 방식은 층화추출법(Stratified Sampling)입니다.
